

탐색적 데이터 분석(EDA) 및 시각화

2026-2 COW AI팀 사전 과제 · 1주차

김효준

2026년 7월 31일

요약

분석 주제: DAICON 갑상선암 진단 분류 데이터 (양성/악성 이진 분류)
학습 87,159건 · 평가 46,204건 · 설명변수 14개 · 타겟 Cancer (악성 비율 12.0%)

차례

1-1. 탐색적 데이터 분석(EDA)이란 무엇이며 왜 수행하는가	1
1-2. 데이터 분석 및 시각화	3
1-3. 분석 결과	13
1-4. 전처리 계획	15
마무리	18
참고 문헌	18

1-1. 탐색적 데이터 분석(EDA)이란 무엇이며 왜 수행하는가

EDA의 정의

탐색적 데이터 분석(Exploratory Data Analysis, EDA)은 John W. Tukey가 1977년 저서 Exploratory Data Analysis에서 체계화한 접근법으로, **사전에 세운 가설을 검증하기 이전에 데이터 자체가 무엇을 말하는지 그림과 요약통계로 먼저 들어보는 과정**이다. Tukey는 이를 확증적 자료 분석(Confirmatory Data Analysis)과 대비시키며, 분석의 출발점은 가설이 아니라 데이터여야 한다고 주장했다.

EDA의 목적

목적	구체적 내용
데이터 이해	행·열의 규모, 자료형, 각 변수의 의미와 값의 범위를 파악한다
품질 진단	결측치, 중복, 이상치, 논리적으로 불가능한 값을 찾아낸다
구조 발견	변수 간 상관·연관, 그룹별 차이, 상호작용 등 숨은 패턴을 찾는다
모델링 전략 수립	전처리 방법, 파생변수, 알고리즘, 평가지표 선택의 근거를 마련한다

목적	구체적 내용
가설 생성	후속 단계에서 검증할 구체적인 질문을 만든다

EDA를 수행해야 하는 이유

1. 전처리와 모델링의 모든 의사결정에 근거를 제공한다.

“결측치를 평균으로 채운다”, “로그 변환을 한다” 같은 선택은 그 자체로 옳고 그름이 없다. 분포가 어떤 모양인지, 결측이 어떤 메커니즘으로 발생했는지 확인한 뒤에야 정당화된다. EDA 없는 전처리는 관행의 반복일 뿐 근거 있는 설계가 아니다.

2. Garbage In, Garbage Out을 막는다.

아무리 정교한 모델도 잘못된 데이터를 바로잡아 주지는 않는다. 중복 행, 라벨 오류, 데이터 누수(leakage)는 모델 성능을 실제보다 부풀리거나 반대로 망가뜨리는데, 이런 문제는 학습 이후가 아니라 EDA 단계에서만 저렴하게 발견된다.

3. 요약통계만으로는 데이터를 알 수 없기 때문이다.

Anscombe's Quartet(1973)과 Datasaurus Dozen(2017)은 **평균·분산·상관계수가 완전히 동일하면서도 전혀 다른 모양을 가진 데이터셋**을 제시했다. 숫자만 보고 데이터를 안다고 말할 수 없으며 반드시 그려 봐야 한다는 것이 EDA의 핵심 논거다.

4. 단변량 통계는 상호작용을 놓친다.

개별 변수와 타깃의 상관이 0에 가깝더라도, 두 변수의 **조합**에서는 강한 신호가 존재할 수 있다. 심프슨의 역설(Simpson's Paradox)이 대표적이다. 본 과제의 데이터가 정확히 이 경우에 해당하며, 자세한 내용은 1-3절에서 다룬다.

5. 평가 설계를 좌우한다.

클래스 불균형 여부를 모른 채 Accuracy를 보면, 아무것도 학습하지 않은 모델이 88%를 기록하는 착시에 빠진다. 어떤 지표를 볼 것인지, 데이터를 어떻게 분할할 것인지는 EDA 결과에서 나온다.

1-2. 데이터 분석 및 시각화

(1) 데이터 기본 정보

항목	내용
학습 데이터	87,159행 × 16열
평가 데이터	46,204행 × 15열 (타깃 제외)
타깃 변수	Cancer (1 = 악성, 0 = 양성)
식별자	ID
수치형 변수	5개 — Age, Nodule_Size, TSH_Result, T4_Result, T3_Result
범주형 변수	9개 — Gender, Country, Race, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes
결측치	train 0건 / test 0건
중복 행	0건 (ID 제외 기준)

변수 설명

변수	유형	의미	값의 범위
Age	수치	나이	14 ~ 88
Gender	범주	성별	M / F
Country	범주	국가	10개국
Race	범주	인종	ASN / AFR / CAU / HSP / MDE
Family_Background	범주	가족력	Positive / Negative
Radiation_History	범주	방사선 노출 이력	Exposed / Unexposed
Iodine_Deficiency	범주	요오드 결핍	Deficient / Sufficient
Smoke	범주	흡연 여부	Smoker / Non-Smoker
Weight_Risk	범주	비만 여부	Obese / Not Obese
Diabetes	범주	당뇨 여부	Yes / No
Nodule_Size	수치	결절 크기	0.00 ~ 5.00
TSH_Result	수치	갑상선자극호르몬	0.10 ~ 10.00
T4_Result	수치	티록신(T4)	4.50 ~ 12.00
T3_Result	수치	삼요오드티로닌(T3)	0.50 ~ 3.50

(2) 클래스(Target) 분포




그림 1: 타겟 클래스 분포

클래스	건수	비율
0 (양성)	76,700	88.00%
1 (악성)	10,459	12.00%

불균형 비율은 약 **1:7.33**이다. 전체를 0으로 예측하는 무의미한 모델도 Accuracy 88%를 기록하므로, **Accuracy를 주지표로 삼아서는 안 된다**. 실제로 이 데이터를 사용한 DACON 해커톤의 공식 평가지표도 F1 Score이다.

(3) 수치형 변수의 분포




그림 2: 수치형 변수 히스토그램

변수	평균	표준편차	최소	최대	왜도	첨도
Age	50.860	21.639	14.00	88.00	0.006	-1.199
Nodule_Size	2.508	1.442	0.00	5.00	-0.007	-1.197
TSH_Result	5.057	2.861	0.10	10.00	-0.000	-1.201
T4_Result	8.249	2.166	4.50	12.00	0.002	-1.202
T3_Result	2.005	0.867	0.50	3.50	-0.000	-1.203

다섯 변수 모두 왜도 ≈ 0 , 첨도 ≈ -1.2 이다. 균등분포의 이론적 첨도값은 정확히 -1.2 이며, 관측값이 소수점 둘째 자리까지 이와 일치한다. 즉 실제 임상 데이터의 자연스러운 분포(TSH는 통상 로그정규 형태)가 아니라, **정해진 구간에서 균일하게 생성된 합성 데이터(synthetic data)**로 판단된다. 이 관찰은 이후의 이상치 판단과 스케일링 전략에 직접적인 영향을 준다.

(4) 범주형 변수의 분포





그림 3: 범주형 변수 분포

(5) 변수 간 상관관계

수치형 변수는 Pearson 상관계수로, 범주형 변수는 카이제곱 검정에 기반한 **Cramér's V**로 타깃과의 연관 강도를 측정했다.

그림 4: 수치형 상관행렬 (색상 범위를 ± 0.05 로 확대)

색상 범위를 ± 0.05 로 확대하지 않으면 모든 칸이 흰색으로만 보인다. 실제 상관계수의 절댓값이 전부 0.01 미만이기 때문이다. 시각화 시 스케일을 조정해야 “상관이 없다”는 사실 자체를 확인할 수 있다.




그림 5: 변수별 타깃 연관 강도 순위

변수	유형	연관 강도	p-value	판정
Race	범주 (Cramér's V)	0.1260	< 0.001	유의
Family_Background	범주 (Cramér's V)	0.1071	< 0.001	유의

변수	유형	연관 강도	p-value	판정
Country	범주 (Cramér's V)	0.0959	< 0.001	유의
Iodine_Deficiency	범주 (Cramér's V)	0.0799	< 0.001	유의
Radiation_History	범주 (Cramér's V)	0.0749	< 0.001	유의
TSH_Result	수치 (점이연 r)	0.0082	0.015	형식상 유의
T3_Result	수치 (점이연 r)	0.0035	0.297	신호 없음
T4_Result	수치 (점이연 r)	0.0033	0.329	신호 없음
Weight_Risk	범주 (Cramér's V)	0.0022	0.509	신호 없음
Nodule_Size	수치 (점이연 r)	0.0011	0.751	신호 없음
Age	수치 (점이연 r)	0.0009	0.797	신호 없음
Smoke	범주 (Cramér's V)	0.0006	0.852	신호 없음
Gender	범주 (Cramér's V)	0.0006	0.861	신호 없음
Diabetes	범주 (Cramér's V)	0.0002	0.943	신호 없음

TSH_Result는 $p = 0.015$ 로 형식상 유의하게 나오지만 상관계수는 -0.008 에 불과하다. 이는 표본이 87,159건으로 매우 크기 때문에 발생하는 현상이며, **통계적 유의성과 실질적 효과 크기는 다르다**는 점을 보여주는 사례다. 실무적으로는 신호가 없다고 보아야 한다.

(6) 주요 변수별 시각화 — 타깃에 따른 분포 비교




그림 6: 수치형 변수의 타깃별 Boxplot 및 Histogram

두 클래스의 상자와 밀도곡선이 사실상 완전히 겹친다. 평균 차이도 최대 0.072(TSH)에 불과하다. **수치형 변수만으로는 양성과 악성을 구분할 수 없다.**

이상치 점검 결과 (IQR 방식)

변수	실제 범위	IQR 하한	IQR 상한	이상치 수
Age	14.00 ~ 88.00	-25.00	127.00	0
Nodule_Size	0.00 ~ 5.00	-2.47	7.50	0
TSH_Result	0.10 ~ 10.00	-4.86	14.98	0
T4_Result	4.50 ~ 12.00	0.74	15.76	0
T3_Result	0.50 ~ 3.50	-1.00	5.01	0

IQR 기준 이상치가 단 한 건도 없다. 실제 관측 범위가 IQR 경계 안쪽에 완전히 들어가 있기 때문이다. 의학적으로 불가능한 값(음수 나이, 0 이하의 호르몬 수치 등)도 존재하지 않는다.

(7) 범주형 변수별 암 발생률




그림 7: 범주형 변수 수준별 암 발생률 (점선 = 전체 평균 12.0%)

Gender, Smoke, Weight_Risk, Diabetes는 모든 수준이 12.0% 선에 붙어 있다(회색). 반면 Race(ASN 18.6% vs HSP 8.6%), Family_Background(17.5% vs 9.8%), Country(IND 18.4% vs USA 9.4%)는 뚜렷한 차이를 보인다.

(8) 핵심 분석 — 단변량 분석이 놓친 상호작용 구조

여기까지의 결과는 “몇몇 범주형 변수에 약한 신호가 있다” 정도로 요약된다. 그런데 Cramér’s V의 최댓값이 0.126에 불과하다는 점이 의문이었다. 신호가 정말 이 정도로 약한 것일까?

변수를 하나씩 보는 대신 조합해서 보면 완전히 다른 그림이 나타난다.




그림 8: 인종별 조건부 암 발생률 (%)

인종	표본 수	전체 발생률	가족력 격차	방사선 격차	요오드 격차
AFR	17,155	13.62%	-1.09%p	+43.79%p	+5.79%p
ASN	20,363	18.60%	+42.34%p	+0.16%p	+4.41%p
CAU	27,090	8.78%	+0.03%p	-0.17%p	+6.88%p
HSP	13,471	8.60%	+0.05%p	+0.35%p	+6.69%p
MDE	9,080	8.79%	-0.45%p	+0.32%p	+6.97%p

결정적인 발견이다.

- Race = ASN일 때만 Family_Background가 작동한다 → Positive 51.3% vs Negative 9.0% (격차 **42.3%p**)
- Race = AFR일 때만 Radiation_History가 작동한다 → Exposed 52.5% vs Unexposed 8.7% (격차 **43.8%p**)
- CAU, HSP, MDE는 어떤 요인에도 반응하지 않고 8.6~8.8%에 고정되어 있다.

전체 데이터에서 Family_Background의 효과가 17.5% vs 9.8%(약 7.7%p)로 약해 보였던 이유는, **실제 42%p 짜리 효과가 ASN이 아닌 76.6%의 표본에 희석되었기 때문이다**. 이것이 심프슨의 역설이 작동하는 방식이다.

동일한 패턴이 Country에서도 반복된다.

요오드 결핍 효과는 인도(IND)에서만 나타난다




그림 9: 요오드 결핍 효과는 인도(IND)에서만 나타난다

집단	요오드 결핍군	요오드 충분군	격차
Country = IND	51.39% (n=3,102)	10.71% (n=13,207)	+40.68%p
Country ≠ IND	10.55% (n=17,705)	10.50% (n=53,145)	+0.05%p

Iodine_Deficiency는 인도에서만 51.4% vs 10.7%의 격차를 만들고, 나머지 9개국에서는 10.55% vs 10.50%로 차이가 사실상 0이다. 단변량 분석에서 이 변수의 Cramér's V가 0.080밖에 되지 않았던 것은, 인도가 전체 표본의 18.7%에 불과하기 때문이다.

(9) 발견한 구조의 검증 — 규칙 기반 재현

세 개의 조건부 규칙만으로 타깃을 얼마나 설명할 수 있는지 정량적으로 확인했다.




그림 10: 규칙 해당 개수별 암 발생률 및 Confusion Matrix

규칙	해당 건수	전체 대비	암 발생률	전체 양성 중 비중
R1. Race=ASN AND Family_Background=Positive	4,631	5.31%	51.31%	22.72%
R2. Race=AFR AND Radiation_History=Exposed	1,928	2.21%	52.49%	9.68%
R3. Country=IND AND Iodine_Deficiency=Deficient	3,102	3.56%	51.39%	15.24%

규칙	해당 건수	전체 대비	암 발생률	전체 양성 중 비중
해당 없음 (기저)	77,826	89.29%	7.25%	53.93%

규칙 3개만으로 예측했을 때의 성능 (학습 데이터 기준)

지표	규칙 기반 예측	모두 0으로 예측
Accuracy	0.8835	0.8800
Precision	0.5163	—
Recall	0.4608	0.0000
F1-score	0.4870	0.0000

파생변수 3개, 하이퍼파라미터 0개, 학습 과정 없는 순수 규칙만으로 **F1 = 0.487**이 나온다. 반면 원본 변수를 그대로 넣은 선형 모델은 이 상호작용을 표현할 수 없어 훨씬 낮은 성능에 그친다. **2주차 Feature Engineering의 방향이 여기서 결정된다.**

기저 그룹의 잔여 신호 탐색

규칙에 해당하지 않는 77,826건에 대해 9개 범주형 변수 각각의 발생률 격차를 측정한 결과는 다음과 같다.

변수	최대 발생률 격차	변수	최대 발생률 격차
Country	1.37%p	Family_Background	0.30%p
Race	0.50%p	Gender	0.27%p
Weight_Risk	0.23%p	Smoke	0.10%p
Radiation_History	0.09%p	Iodine_Deficiency	0.08%p
Diabetes	0.01%p		

어떤 변수로도 7.25%의 기저 발생률을 유의미하게 꼬갤 수 없다. **전체 양성**의 약 53.9%(5,640건)는 어떤 모델로도 설명할 수 없는 잡음(irreducible noise)이며, 이는 달성 가능한 F1에 명확한 상한이 존재함을 의미한다.

(10) train / test 분포 일치 여부

학습 데이터에서 얻은 통계량(스케일러 파라미터, 인코딩 매핑 등)을 평가 데이터에 그대로 적용해도 되는지 판단하기 위해 두 데이터의 분포를 검정했다.




그림 11: train / test 분포 비교

변수	KS 통계량	p-value	train 평균	test 평균
Age	0.0032	0.922	50.860	50.928
Nodule_Size	0.0063	0.181	2.508	2.499
TSH_Result	0.0041	0.698	5.057	5.064
T4_Result	0.0030	0.951	8.249	8.247
T3_Result	0.0059	0.239	2.005	2.012

모든 수치형 변수의 KS 검정 p-value가 0.18을 넘고, 범주형 비율 차이도 최대 1.03%p(Race)에 그친다. **분포 이동(distribution shift)이 없으므로 train 통계량을 test에 적용해도 안전하다.**

1-3. 분석 결과

① 데이터 불균형 — 존재함 (약 8:1)

클래스	건수	비율
0 (양성)	76,700	88.00%
1 (악성)	10,459	12.00%

전체를 0으로 찍기만 해도 Accuracy 88%가 나온다. 따라서 **Accuracy는 주지표로 부적합**하며 F1-score를 중심으로 Precision과 Recall의 균형을 봐야 한다. 임계값(threshold) 조정, class_weight='balanced', 계층적 분할(stratified split)이 필수적으로 요구된다.

② 결측치 — 존재하지 않음

train 87,159행, test 46,204행 전체에서 결측치가 **0건**이다. 완전 중복 행도 없고 ID 중복도 없다. 2주차의 결측치 처리 항목은 실제 적용 대상이 없으므로, **인위적 결측 주입 실험**을 통해 방법론을 설명하는 방식으로 대체할 계획이다.

③ 이상치 — 존재하지 않음 (통계적으로도, 의학적으로도)

IQR 기준 이상치가 5개 수치형 변수 모두에서 0건이다. 이는 데이터가 우연히 깨끗해서가 아니라 **모든 변수가 유한 구간의 균등분포로 생성되었기 때문**이다. 균등분포의 이론적 첨도는 -1.2이며 관측된 첨도가 -1.197 ~ -1.203으로 이와 일치한다. 따라서 **이상치 제거·클리핑·로그변환은 모두 적용할 이유가 없다**.

④ 상관관계가 높은 변수 — 단변량으로는 없음, 조합에서는 매우 강함

(a) **수치형 5개는 전부 무의미하다**. 타깃과의 상관계수 절댓값이 모두 0.01 미만이며(최대 $|r| = 0.0082$, TSH_Result), 변수 간 다중공선성도 없다(최대 $|r| = 0.0062$). 임상 상식과 달리 결절 크기나 호르몬 수치가 암 여부와 전혀 관련이 없다는 점은, 이 데이터가 합성 데이터라는 판단을 재확인시킨다.

(b) **범주형 9개 중 4개도 완전한 잡음**이다. Gender($p=0.861$), Smoke($p=0.852$), Weight_Risk($p=0.509$), Diabetes($p=0.943$) 모두 타깃과 아무 연관이 없다.

(c) **진짜 구조는 3개의 상호작용에 있다** — 본 EDA의 핵심 발견

조건	해당 건수	암 발생률	대조군	격차
Race=ASN AND Family_Background=Positive	4,631	51.3%	ASN·Negative 9.0%	42.3%p
Race=AFR AND Radiation_History=Exposed	1,928	52.5%	AFR·Unexposed 8.7%	43.8%p
Country=IND AND Iodine_Deficiency=Deficient	3,102	51.4%	IND·Sufficient 10.7%	40.7%p
위 어느 것에도 해당하지 않음	77,826	7.25%	—	—

각 위험요인은 **특정 집단 안에서만** 작동한다. 예컨대 가족력은 ASN에서 42.3%p의 격차를 만들지만 AFR에서는 -1.1%p, CAU에서는 0.03%p로 아무 효과가 없다. 전체 평균으로 뭉개서 보면 가족력 효과가 7.7%p로 축소되어 보이는데, 이것이 심프슨의 역설이다.

(d) 검증 — 위 3개 규칙만으로 예측하면 $F1 = 0.487$ (Accuracy 0.884, Precision 0.516, Recall 0.461)이 나온다. 학습도 튜닝도 없는 규칙만으로 이 정도가 나온다는 것은, 이 데이터의 신호가 개별 변수가 아니라 **조합에 들어 있음**을 결정적으로 보여준다.

(e) 성능 상한의 존재 — 규칙에 해당하지 않는 기저 그룹(77,826건, 전체의 89.3%)에서는 어떤 변수를 넣어도 발생률 격차가 최대 1.37%p에 불과하다. 이 그룹의 7.25%, 즉 전체 양성 약 53.9%(5,640건)는 **어떤 모델로도 설명할 수 없는 잡음**이다. 따라서 3주차에서 F1이 0.5 부근에서 정체되더라도 그것은 모델의 실패가 아니라 데이터의 구조적 한계이며, 이 점을 미리 인지하고 평가해야 한다.

⑤ train / test 분포 — 완전히 일치

수치형 5개의 KS 검정 p-value가 모두 0.18 이상이고, 범주형 비율 차이도 최대 1.03%p다. 분포 이동이 없으므로 train에서 학습한 전처리 파라미터를 test에 그대로 적용해도 무방하다.

⑥ 전처리가 필요한 컬럼 요약

구분	컬럼	필요한 처리
반드시 필요	범주형 9개	인코딩 (모델이 문자열을 받지 못함)
반드시 필요	Race, Country, Family_Background, Radiation_History, Iodine_Deficiency	상호작용 파생변수 생성
조건부 필요	수치형 5개	거리·경사 기반 모델 사용 시에만 스케일링
제거 후보	Gender, Smoke, Weight_Risk, Diabetes	신호 없음 — 제거 여부를 실험으로 결정
제거	ID	식별자
불필요	전 컬럼	결측치 처리, 이상치 처리 (대상 없음)

1-4. 전처리 계획

2주차에 수행할 전처리를 **무엇을 / 어떻게 / 왜**의 형태로 정리한다.

계획 1. 결측치 처리 — 적용 대상 없음, 방법론은 실험으로 검증

- **대상:** 없음 (train/test 모두 결측 0건)
- **방법:** 실제 처리 대신, 임의로 결측을 주입한 사본을 만들어 ① 단순 삭제 ② 평균·중앙값 대체 ③ 최빈값 대체 ④ 결측 자체를 하나의 범주로 처리하는 네 가지를 비교하고 성능 영향을 측정한다.
- **이유:** 처리할 결측이 없다고 해서 항목을 생략하면 과제 요구사항을 충족하지 못한다. 통제된 실험으로 각 기법의 특성을 보이는 편이 형식적인 설명보다 낫다. 특히 이 데이터는 균등분포이므로 **평균 대체가 분포를 왜곡하는 정도**를 시각적으로 보여주기에 적합하다.

계획 2. 이상치 처리 — 적용하지 않음 (근거 제시)

- **대상:** 없음
- **방법:** IQR·Z-score·백분위 클리핑 세 기준으로 재확인한 뒤, **처리하지 않는다**는 결론을 명시한다.
- **이유:** 모든 변수가 유한 구간 균등분포(첨도 ≈ -1.2)라 정의상 꼬리가 없다. 기계적으로 상하위 1%를 자르면 **정보만 잃고 얻는 것이 없다**. “적용하지 않기로 결정했다”는 것도 근거가 있다면 유효한 전처리 결정이다.

계획 3. 인코딩 — 변수별로 다르게 적용

대상	방법	이유
이진 범주 7개 (Gender, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes)	Binary(0/1) 매핑	수준이 2개뿐이라 One-Hot을 써도 열만 늘어날 뿐 정보량이 같다
Race (5수준)	One-Hot	순서가 없는 명목형. 수준이 적어 차원 증가 부담이 없다
Country (10수준)	One-Hot + is_IND 별도 플래그	IND만 특별한 역할을 하므로 명시적 플래그를 추가한다

- **Label Encoding을 쓰지 않는 이유:** ASN=0, AFR=1, CAU=2 식으로 부여하면 존재하지 않는 순서 관계를 모델에 주입하게 된다. 트리 모델은 건디지만 선형 모델에서는 해석이 무너진다.
- **Target Encoding을 1순위로 쓰지 않는 이유:** 타깃 정보를 특징에 넣는 방식이라 데이터 누수(leakage) 위험이 있다. 사용한다면 Out-of-Fold 방식으로 제한하고, 3주차에 비교 검증한다.

계획 4. Scaling — 모델에 따라 조건부 적용

- **대상:** Age, Nodule_Size, TSH_Result, T4_Result, T3_Result
- **방법:** MinMaxScaler를 기본으로 하고 StandardScaler와 성능을 비교한다. 트리 계열(Random Forest, XGBoost, LightGBM)에는 **적용하지 않는다**.
- **이유:**
 - 다섯 변수의 범위가 0~5, 0.1~10, 4.5~12, 14~88로 제각각이라, 거리 기반(KNN)·경사하강 기반(Logistic Regression, SVM) 모델에서는 스케일이 큰 Age가 거리 계산을 지배한다.
 - **MinMaxScaler를 선택한 근거:** 이 변수들은 정규분포가 아니라 **균등분포**다. 평균 0·표준편차 1로 맞추는

StandardScaler는 정규성을 가정할 때 의미가 크지만, 상하한이 명확한 균등분포에서는 [0,1] 구간으로 선형 사상하는 MinMax가 원래 형태를 그대로 보존한다. 또한 이상치가 없으므로 MinMax의 최대 약점인 극단값 민감성이 문제되지 않는다.

- 트리 모델은 분할 기준이 값의 크기가 아닌 순서에 의존하므로 스케일링이 성능에 영향을 주지 않는다.

계획 5. Feature Engineering — 본 과제의 핵심

EDA에서 발견한 상호작용 구조를 명시적 변수로 만든다. **이것이 성능을 좌우한다.**

(a) 상호작용 플래그 3개 — 1순위

```
df['ASN_Family'] = (df.Race == 'ASN') & (df.Family_Background == 'Positive')
df['AFR_Radiation'] = (df.Race == 'AFR') & (df.Radiation_History == 'Exposed')
df['IND_Iodine'] = (df.Country == 'IND') & (df.Iodine_Deficiency == 'Deficient')
```

- **이유:** 이 세 변수만으로 F1 0.487이 나온다는 것을 1-2절 (9)에서 확인했다. 선형 모델은 원본 변수만으로 이 구조를 절대 표현할 수 없고, 트리 모델도 깊이가 충분해야 스스로 찾아낸다. 명시적으로 주면 학습이 훨씬 쉬워진다.

(b) 위험요인 개수 집계

```
df['n_risk'] = df.ASN_Family + df.AFR_Radiation + df.IND_Iodine
```

- **이유:** 규칙 해당 개수(0/1/2)에 따라 발생률이 7.25% → 51.7% → 49.7%로 계단식으로 변한다. 순서형 변수로 압축하면 트리 모델이 단일 분할로 큰 이득을 얻는다.

(c) 위험군 여부 이진 플래그

```
df['is_high_risk'] = (df.n_risk >= 1)
```

(d) 검증할 가설 — 저신호 변수 제거

- Gender, Smoke, Weight_Risk, Diabetes 4개를 제거한 버전과 유지한 버전을 각각 학습해 성능을 비교한다.
- **이유:** p-value가 0.509~0.943으로 신호가 전혀 없어 트리 모델에서 무의미한 분할을 유발할 수 있다. 다만 “약한 신호”와 “잡음”을 사전에 단정하기보다 **실험으로 확인**하는 것이 안전하다.

(e) 시도하되 기대는 낮게 — 수치형 파생

- T3/T4 비율, TSH × Nodule_Size, Age 구간화 등을 만들어 본다.
- **이유:** 원 변수의 신호가 $|r| < 0.01$ 이므로 성공 가능성은 낮다. 다만 임상적으로 T3/T4 비율은 갑상선 기능 평가에 사용되는 지표이므로, 데이터 생성 과정에 반영되었을 가능성을 배제하지 않고 한 번은 검증한다.

계획 6. 데이터 분할 전략 (3주차 대비)

- **방법:** train_test_split(..., stratify=y, test_size=0.2, random_state=42) 및 StratifiedKFold(n_splits=5) 교차검증
- **이유:** 양성 비율이 12%이므로 무작위 분할 시 폴드별 양성 비율이 흔들려 평가가 불안정해진다. 계층적 분할로 각 폴드의 클래스 비율을 12%로 고정해야 한다.

전처리 계획 요약

#	항목	대상	방법	우선순위
1	결측치	없음	인위적 주입 후 기법 비교	낮음
2	이상치	없음	미적용 (근거 제시)	낮음

#	항목	대상	방법	우선순위
3	인코딩	범주형 9개	Binary + One-Hot	필수
4	Scaling	수치형 5개	MinMax (트리 모델 제외)	중간
5	Feature Engineering	상호작용	플래그 3개 + 개수 집계	최우선
6	컬럼 제거	ID / 저신호 4개	ID 제거, 나머지는 실험 후 결정	중간
7	데이터 분할	전체	Stratified 5-Fold	필수

마무리

이번 EDA의 가장 중요한 결론은, **개별 변수의 상관관계수만 보고 “쓸 만한 변수가 없다”고 판단했다면 이 데이터의 실제 구조를 완전히 놓쳤을 것**이라는 점이다.

Cramér's V 최댓값 0.126, 수치형 상관관계수 절댓값 0.01 미만이라는 수치는 데이터에 신호가 거의 없다는 인상을 준다. 그러나 변수를 조합하자 40%p가 넘는 격차를 가진 세 개의 규칙이 드러났고, 이 규칙만으로 F1 0.487을 얻었다.

동시에, 규칙으로 설명되지 않는 기저 그룹에는 어떤 잔여 신호도 남아 있지 않다는 점도 확인했다. 전체 양성의 약 53.9%는 구조적으로 예측이 불가능하다. 이는 3주차에서 달성 가능한 성능에 명확한 상한이 있음을 뜻하며, 무리한 튜닝으로 이 벽을 넘으려 하기보다 **상호작용 특징을 제대로 만들어 상한에 최대한 근접시키는 것**이 올바른 전략임을 시사한다.

참고 문헌

1. Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
2. Anscombe, F. J. (1973). “Graphs in Statistical Analysis.” The American Statistician, 27(1), 17–21. <https://www.jstor.org/stable/2682899>
3. Matejka, J., & Fitzmaurice, G. (2017). “Same Stats, Different Graphs: Generating Datasets with Varied Appearance and Identical Statistics through Simulated Annealing.” CHI 2017. <https://www.research.autodesk.com/publications/same-stats-different-graphs/>
4. DAICON. “갑상선암 진단 분류 해커톤 : 양성과 악성, AI로 정확히 구분하라!” <https://dacon.io/competitions/official/236488/overview/description>
5. Wikipedia. “Simpson’s paradox.” https://en.wikipedia.org/wiki/Simpson%27s_paradox
6. Cramér, H. (1946). Mathematical Methods of Statistics. Princeton University Press. (Cramér’s V)
7. scikit-learn developers. “Preprocessing data — scikit-learn User Guide.” <https://scikit-learn.org/stable/modules/preprocessing.html>
8. seaborn developers. “seaborn: statistical data visualization.” <https://seaborn.pydata.org/>
9. Massey, F. J. (1951). “The Kolmogorov-Smirnov Test for Goodness of Fit.” Journal of the American Statistical Association, 46(253), 68–78.
10. He, H., & Garcia, E. A. (2009). “Learning from Imbalanced Data.” IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284.