

탐색적 데이터 분석(EDA) 및 시각화

1. 탐색적 데이터 분석(EDA)

1-1. EDA의 목적

탐색적 데이터 분석(EDA)은 통계적 요약과 시각화를 통해 데이터의 구조와 특성을 다각도로 파악하는 과정이다. 변수의 타입, 분포, 상관관계를 시각적으로 확인하고, 데이터 규모(행·열)를 측정하여 과적합 위험과 연산 자원을 고려한 분석 방식을 정립한다. 또한, 학습 및 테스트 데이터의 분포 균형, 컬럼별 결측치 비율, 라벨의 클래스 불균형 문제를 사전에 점검하며, 박스플롯과 히스토그램을 활용해 이상치나 입력 오류 등 데이터 특이점을 발견하는 것을 목적으로 한다.

1-2. EDA를 수행해야 하는 이유

EDA는 결측치·이상치·중복 데이터 등 품질 문제를 사전 정제하여 분석 오염을 방지하고, 시각화를 통해 데이터 구조를 명확히 이해하도록 돕는다. 이를 통해 데이터 특성에 부합하는 전처리 기법을 선택하고 변수 간 관계에 기반한 최적의 모델링 전략을 수립할 수 있다. 결과적으로 방해 요소인 노이즈 변수를 제거하고 유의미한 변수만 남김으로써 머신러닝 모델의 전반적인 성능과 품질을 극대화할 수 있다.

2. 데이터 분석 및 시각화

2-1. 데이터 기본 정보

항목	내용
전체 데이터 형태	87,159행 X 16열
결측치	전체 16개 컬럼 모두 결측치 0건 (0.0%)
ID	Object, Unique 87,159개 (전체 행과 동일 → 완전한 고유 식별자)
수치형 컬럼 (5개)	Age(int64), Nodule_Size(float64), TSH_Result(float64), T4_Result(float64), T3_Result(float64)
범주형 컬럼 (9개)	Gender(2), Country(10), Race(5), Family_Background(2), Radiation_History(2), Iodine_Deficiency(2), Smoke(2), Weight_Risk(2), Diabetes(2)
Target	Cancer (int64, 0/1 이진분류)

=== 컬럼별 프로파일링 요약 ===					
	dtype	결측치_개수	결측치_비율(%)	Unique_개수	샘플값
ID	object	0	0.0	87159	[TRAIN_00000, TRAIN_00001, TRAIN_00002]
Age	int64	0	0.0	75	[80, 37, 71]
Gender	object	0	0.0	2	[M, F]
Country	object	0	0.0	10	[CHN, NGA, IND]
Race	object	0	0.0	5	[ASN, MDE, HSP]
Family_Background	object	0	0.0	2	[Positive, Negative]
Radiation_History	object	0	0.0	2	[Exposed, Unexposed]
Iodine_Deficiency	object	0	0.0	2	[Sufficient, Deficient]
Smoke	object	0	0.0	2	[Non-Smoker, Smoker]
Weight_Risk	object	0	0.0	2	[Not Obese, Obese]
Diabetes	object	0	0.0	2	[No, Yes]
Nodule_Size	float64	0	0.0	501	[0.650355, 2.95043, 2.200023]
TSH_Result	float64	0	0.0	86590	[2.784735, 0.911624, 0.717754]
T4_Result	float64	0	0.0	86473	[6.744603, 7.303305, 11.137459]
T3_Result	float64	0	0.0	85302	[2.57582, 2.505317, 2.38108]
Cancer	int64	0	0.0	2	[1, 0]


2-2. 각 컬럼의 데이터 분포

* 수치형 변수 기초 통계량

	count	mean	std	min	25%	50%	75%	max
Age	87159.0	50.860244	21.638687	14.0	32.000000	51.000000	70.000000	88.0
Nodule_Size	87159.0	2.508098	1.441928	0.0	1.270332	2.520941	3.760938	5.0
TSH_Result	87159.0	5.056871	2.861229	0.1	2.582845	5.059085	7.541586	10.0
T4_Result	87159.0	8.248796	2.165975	4.5	6.372031	8.236789	10.126981	12.0
T3_Result	87159.0	2.005002	0.867013	0.5	1.254836	2.004101	2.758032	3.5
Cancer	87159.0	0.119999	0.324962	0.0	0.000000	0.000000	0.000000	1.0


5개 수치형 변수 모두 평균과 중앙값이 거의 일치함. 최소~최대 범위 안에서 사분위수 간격도 대체로 균등하게 나뉘어 있어, 각 변수가 특정 값에 몰리지 않고 고르게 퍼진 형태임을 알 수 있음.

* 수치형 변수별 Boxplot



Boxplot 상 어느 변수에서도 박스 바깥으로 튀는 점(이상치)이 관찰되지 않으며, 사분위 범위(IQR box)가 전체 범위에 걸쳐 고르게 분포함. 왜도도 5개 변수 모두 0에 근접하여, 정규분포보다는 평범한 사다리꼴에 가까운 균일 분포 형태로 판단됨.


2-3. 클래스(Target) 분포



Class	개수	비율
0(양성)	76,700	88.0%
1(악성/재발)	10,459	12.0%

Cancer 평균값이 0.12로, 이는 곧 Class1의 비율과 정확히 일치함. 7.3:1의 뚜렷한 불균형 구조가 확인됨.


2-4. 변수 간 상관관계



Pearson(선형)과 Spearman(순위/비선형) 두 방식으로 계산한 상관계수를 히트맵으로 비교. 수치형 변수 간 상관 계수가 대부분 -0.01 ~ 0.01 수준으로 매우 낮고, Cancer와의 상관계수도 모든 변수에서 $|r| \leq 0.01$ 수준으로 미미함. 두 계산 방식 간 결과 차이도 거의 없어(비선형 관계 부재), 변수들이 서로 독립적으로 분포함을 시사함.


2-5. 주요 변수별 시각화

* 수치형 변수 – Cancer 그룹별 KDE Density Plot & Violin Plot



대부분의 변수에서 Cancer 그룹 (0/1) 간 분포 형태가 거의 겹쳐 보이나, TSH_Result에서만 두 그룹 간 미세한 위치 차이가 관찰됨. ($P = 0.0152$ 로 5개 수치형 변수 중 유일)

* 범주형 변수 – 위험 요인별 Cancer 발생률



Radiation_History, Family_Background, Iodine_Deficiency 3개의 변수는 그룹 간 발생률 차이가 육안으로도 뚜렷하게 보이는 반면, Gender, Smoke, Weight_Risk, Diabetes 4개 변수는 그룹 간 막대 높이가 거의 동일하여 Cancer 여부와 큰 관련이 없는 것으로 판단됨.

3. 분석 결과

3-1. 데이터 불균형 여부

Class	개수	비율
0 (양성)	76,700	88.0%
1 (악성/재발)	10,459	12.0%
Imbalance Ratio		7.3 : 1

Cancer 클래스는 7.3 : 1 비율의 중등도 불균형 구조를 보임. Accuracy만으로 모델을 평가할 경우 소수 클래스(1)를 전혀 예측하지 못해도 88% 수준의 정확도가 산출될 수 있어, 이후 모델 평가에서는 Recall, F1-score, ROC-AUC 등 불균형에 강건한 지표를 우선 고려해야 함.

3-2. 이상치 존재 여부

=== 왜도 및 IQR 이상치 진단표 ===

	변수	Skewness	Log변환_권장 (Skew >1)	IQR_하한	IQR_상한	이상치_개수	이상치_비율(%)
0	Age	0.006	불필요	-25.00	127.00	0	0.0
1	Nodule_Size	-0.007	불필요	-2.47	7.50	0	0.0
2	TSH_Result	-0.000	불필요	-4.86	14.98	0	0.0
3	T4_Result	0.002	불필요	0.74	15.76	0	0.0
4	T3_Result	-0.000	불필요	-1.00	5.01	0	0.0

5개 수치형 변수 모두 왜도가 0에 근접하며 IQR 기준 이상치가 전혀 검출되지 않음. 또한 16개 컬럼 전체에서 결측치가 0건으로 확인되어, 결측치 처리와 이상치 제거 모두 별도로 필요하지 않은 것으로 판단됨.

* 통계적으로는 매우 깨끗한 데이터지만, "통계적으로 이상치가 없다"와 "의학적으로 위험한 수치가 없다"는 다른 이야기임. TSH_Result가 병원 기준으로는 이상 수치여도, 데이터 전체에서는 흔한 값이라 이상치로 안 잡힐 수 있음. 이상치를 지우기보다, 의학적 정상 범위 기준의 위험 표시 변수를 만드는 것도 유용할 것으로 판단

3-3. 상관관계가 높은 변수

Pearson-Spearman 차이가 큰 변수쌍 Top 5

	변수1	변수2	Pearson - Spearman 차이
0	Age	TSH_Result	0.000021
1	Nodule_Size	T3_Result	0.000019
2	TSH_Result	T4_Result	0.000013
3	T4_Result	T3_Result	0.000013
4	Nodule_Size	T4_Result	0.000012

모든 변수쌍에서 두 상관계수 간 차이가 0.00003 미만이며, 히트맵 상 상관계수 자체도 대각선을 제외하면 약 -0.01 ~ 0.01 수준으로 사실상 무상관에 가까움. 수치형 변수 간에는 뚜렷한 상관관계(선형,비선형 모두)가 발견되지 않음.

Cancer(Target)와 유의미한 관계를 보인 변수

변수	검정 방법	p-value	유의성(p<0.05)	비고
0 Family_Background	Chi-Square	0.000000	유의함 *	OR = 0.511
1 Iodine_Deficiency	Chi-Square	0.000000	유의함 *	OR = 1.693
2 Radiation_History	Chi-Square	0.000000	유의함 *	OR = 1.772
3 TSH_Result	Mann-Whitney U	0.015190	유의함 *	유일하게 유의한 수치형 변수
4 T3_Result	Mann-Whitney U	0.296410	유의하지 않음	-
5 T4_Result	Mann-Whitney U	0.329290	유의하지 않음	-
6 Weight_Risk	Chi-Square	0.509310	유의하지 않음	OR = 0.985
7 Nodule_Size	Mann-Whitney U	0.749900	유의하지 않음	-
8 Age	Mann-Whitney U	0.795960	유의하지 않음	-
9 Smoke	Chi-Square	0.852380	유의하지 않음	OR = 0.995
10 Gender	Chi-Square	0.861330	유의하지 않음	OR = 0.996
11 Diabetes	Chi-Square	0.942740	유의하지 않음	OR = 0.998

수치형 지표 중 TSH_Result만 유의하고, 범주형 변수 중에서는 Radiation_History, Iodine_Deficiency, Family_Background 3개가 강한 유의성을 보임. 이 데이터셋 안에서는 범주형 위험 요인이 수치형 임상 지표보다 Cancer 판별에 더 큰 정보량을 가진 핵심 변수로 포착됨. 한편 유의하지 않은 범주형 변수(Gender, Smoke, Weight_Risk, Diabetes)의 Odds Ratio는 각각 0.996, 0.995, 0.985, 0.998로 모두 1에 매우 가까운 값을 보임. OR가 1에 가깝다는 것은 해당 요인이 있고 없음이 암 발생 위험을 사실상 높이지도 낮추지도 않는다는 의미로, p-value가 유의하지 않다는 통계 검정 결과와 정확히 일치하는 근거로 판단

3-4. 전처리가 필요한 컬럼

컬럼	전처리 필요 사유
ID	87,159개 전부 고유값 → 분석·모델링 대상에서 제외
TSH_Result, T4_Result, T3_Result	세 지표 간 상호작용(호르몬 피드백 관계)을 반영한 파생 변수 생성 검토
Radiation_History, Iodine_Deficiency, Family_Background	유의성이 가장 높은 핵심 변수 → 인코딩 및 교차 변수 우선 고려
Country(10개 범주), Race(5개 범주)	다범주 변수 → 인코딩 방식 선택 필요
Gender, Smoke, Weight_Risk, Diabetes	단독 유의성은 낮으나 다른 변수와 결합했을 때의 교호작용 재검토
Cancer(Target)	심각한 클래스 불균형(7.3:1) → 오버샘플링/언더샘플링 또는 class_weight 조정 필요

4. 전처리 계획

4-1. 어떤 컬럼을 전처리할 것인지

Radiation_History (범주: Exposed / Unexposed)

4-2. 어떤 방법으로 전처리할 것인지

Label Encoding을 적용함 (Exposed → 1, Unexposed → 0)

4-3. 그 이유

EDA 결과 Radiation_History는 Chi-Square 검정에서 $p < 0.00001$ 로 강하게 유의했고, Odds Ratio가 1.772로 Cancer 판별에 실질적 영향력을 가진 핵심 변수로 확인됨. 다만 이 컬럼은 "Exposed"와 "Unexposed" 단 2개의 범주만 가지고 있어서, One-Hot Encoding처럼 컬럼을 여러 개로 나눌 필요 없이 0과 1로만 바뀌어도 손실 없이 충분히 표현 가능함. 따라서 계산이 더 간단하고 모델 학습 속도에도 유리한 Label Encoding을 선택

항목	내용
컬럼명	Radiation_History
원본 값	Exposed / Unexposed
변환 후 값	1 / 0
선택한 방법	Label Encoding
EDA 근거	Chi-Square $p < 0.00001$, Odds Ratio = 1.772