



1주차 과제

영역 · 자원	COW
고정하기	☐

1-1. 탐색적 데이터 분석(EDA)이란 무엇이며 왜 수행하는지 작성

EDA(Exploratory Data Analysis)란 수집한 데이터를 분석하기 전에 그래프나 통계적인 방법으로 자료를 직관적으로 바라보는 과정입니다.

EDA의 목적은 데이터의 특성, 이상치, 결측치를 파악 및 변수 간 관계 분석, 패턴과 추세 발견, 가설 수립 및 모델링 방향을 결정하는 것입니다.

EDA를 수행해야 하는 이유는 데이터 수집, 전처리 과정에서 미처 발견하지 못했던 문제를 발견할 수 있고, 데이터 간의 패턴 발견 및 데이터 분석 도구를 선정하는 데에 도움이 됩니다.

EDA (Exploratory Data Analysis) 탐색적 데이터 분석 : <https://eda-ai-lab.tistory.com/13>

EDA란? 데이터 분석 초보자를 위한 EDA 방법 5단계 :
https://desilo.ai/insights/blog/eda_data_analysis

1-2. 데이터 분석 및 시각화

다음 내용을 분석하고 시각화하여 데이터의 특징을 작성

- 데이터 기본 정보

컬럼명 (Column)	데이터 타입 (Dtype)	설명 (Description)
show_id	int64	영화 고유 식별 번호
type	object	콘텐츠 유형 (모두 Movie로 구성)
title	object	영화 제목
director	object	연출 감독 이름
cast	object	주요 출연 배우 목록
country	object	제작 국가
date_added	object	플랫폼 등록 날짜 (YYYY-MM-DD)

release_year	int64	영화 개봉 연도
rating	float64	작품 평점 수치
duration	float64	상영 시간 (전건 결측치)
genres	object	영화 장르 (쉼표 구분의 다중 장르)
language	object	영화 주요 언어 코드
description	object	영화 줄거리 요약
popularity	float64	TMDB 플랫폼 내 인기도 지표
vote_count	int64	평점 투표 참여 인원수
vote_average	float64	평균 사용자 평점 수치
budget	int64	영화 제작 예산 (USD)
revenue	int64	박스오피스 총수익 (USD)

- 각 컬럼의 데이터 분포
- 클래스(Target) 분포
- 변수 간 상관관계
- 주요 변수별 시각화(Histogram, Boxplot 등)

사용한 데이터셋 : <https://www.kaggle.com/datasets/bhargavchirumamilla/netflix-movies-and-tv-shows-till-2025>

1-3. 분석 결과

EDA를 통해 발견한 특징을 작성
예시

- 데이터 불균형 여부
- 이상치 존재 여부
- 상관관계가 높은 변수
- 전처리가 필요한 컬럼

type컬럼의 값이 모두 'Movie'로 동일함

buget(예산)과 revenue(수익)의 중앙값이 모두 0, 데이터의 중간 이상이 0으로 채워져 있어서 데이터 쓸림 현상을 보임

popularity(인기도 지표)와 vote_count(평균 투표 참여 인원 수)의 평균값이 중앙값보다 훨씬 큼

popularity(인기도 지표)의 75%지점이 17.33인데 비해 최댓값이 3867.00으로 일부 흥행작에 의해 발생한 이상치 존재(vote_count(평균 투표 참여 인원 수)도 마찬가지임)

budget(예산)과 revenue(수익)의 상관관계가 0.75로 예산이 높을수록 수익도 높게 나타나는 양의 상관관계를 가짐

vote_count(투표수)와 revenue(수익)가 0.75로 양의 상관관계를 가짐

budget(예산)과 vote_count(투표수)가 0.67로 양의 상관관계를 가짐

전체적으로 없거나 불균형한 데이터가 매우 많아서 데이터 전처리 과정을 거쳐도 좋은 모델이 나오기는 어려워 보인다.

1-4. 전처리 계획

EDA 결과를 바탕으로

- 어떤 컬럼을 전처리할 것인지
- 어떤 방법으로 전처리할 것인지
- 그 이유

duration은 100% 모두 결측치 = 삭제 필요

popularity, vote_count는 극단적인 값이 많으므로 로그 변환이나 스케일링이 필요할듯함

vote_average(평균 사용자 평점 수치)와 rating(작품 평점 수치)이 완전히 같은 중복 컬럼이므로 둘중 하나 삭제 필요

budget과 revenue는 0 값의 수가 매우 많음으로 로그 변환또는 0이 들어있는 데이터를 삭제해야 할 듯 함(0 삭제시 남는 데이터의 수는 약 3500개 정도로 보임)

description은 영화 설명으로 따로 모델을 학습하거나 분석을 진행할 때는 필요 없어보임

director, cast, country, genres에 결측치가 존재함

genres는 문자열 데이터로 원핫인코딩 또는 레이블 인코딩을 해야함.