

2026-2 COW AI팀 사전 과제 (1주차)

이상민

2026-08-03

1-1. 탐색적 데이터 분석(EDA)

탐색적 데이터 분석(Exploratory Data Analysis, EDA)은 데이터 분석 및 모델 학습을 수행하기 전에 데이터의 구조와 특성을 파악하는 과정이다. EDA를 통해 데이터의 분포, 이상치, 결측치, 변수 간 관계 등을 확인할 수 있으며, 적절한 전처리와 모델 선택의 근거를 마련할 수 있다.

EDA의 목적

- 데이터 구조 이해
- 데이터 품질 확인
- 변수의 특성 파악
- 변수 간 관계 분석
- 전처리 방향 결정

EDA를 수행해야 하는 이유

EDA를 수행하면 데이터의 문제점을 사전에 발견할 수 있으며, 적절한 전처리를 수행하여 모델의 성능을 향상시킬 수 있다.

1-2. 데이터 분석 및 시각화

데이터준비

```
train <- read.csv("train.csv")
test <- read.csv("test.csv")
```

```
data_info <- data.frame(
  Dataset=c("Train","Test"),
  Rows=c(nrow(train),nrow(test)),
  Columns=c(ncol(train),ncol(test))
)
```

```
)

kable(data_info, caption="Dataset Information") %>%
  kable_styling(full_width=FALSE)
```

Table 1: Dataset Information

Dataset	Rows	Columns
Train	87159	16
Test	46204	15

Train 데이터는 87,159개의 샘플과 16개의 변수로 구성되어 있으며, Test 데이터는 46,204개의 샘플과 15개의 변수로 구성되어 있다. Train 데이터에만 목표 변수(Cancer)가 포함되어 있다.

```
type_df <- data.frame(
  Column=names(train),
  Type=sapply(train,class)
)

kable(type_df)
```

	Column	Type
ID	ID	character
Age	Age	integer
Gender	Gender	character
Country	Country	character
Race	Race	character
Family_Background	Family_Background	character
Radiation_History	Radiation_History	character
Iodine_Deficiency	Iodine_Deficiency	character
Smoke	Smoke	character
Weight_Risk	Weight_Risk	character
Diabetes	Diabetes	character
Nodule_Size	Nodule_Size	numeric
TSH_Result	TSH_Result	numeric
T4_Result	T4_Result	numeric
T3_Result	T3_Result	numeric
Cancer	Cancer	integer

데이터는 수치형 변수와 범주형 변수로 구성되어 있으며, 향후 범주형 변수는 머신러닝 모델 학습을 위해 인코딩이 필요하다.

기초 통계량

```
summary(train)
```

```
##      ID              Age      Gender      Country
## Length:87159      Min.   :14.00  Length:87159      Length:87159
## Class :character  1st Qu.:32.00  Class :character  Class :character
## Mode  :character  Median :51.00  Mode  :character  Mode  :character
##                      Mean   :50.86
##                      3rd Qu.:70.00
##                      Max.   :88.00
##      Race      Family_Background  Radiation_History  Iodine_Deficiency
## Length:87159      Length:87159      Length:87159      Length:87159
## Class :character  Class :character  Class :character  Class :character
## Mode  :character  Mode  :character  Mode  :character  Mode  :character
##
##
##
##      Smoke      Weight_Risk      Diabetes      Nodule_Size
## Length:87159      Length:87159      Length:87159      Min.   :0.000
## Class :character  Class :character  Class :character  1st Qu.:1.270
## Mode  :character  Mode  :character  Mode  :character  Median :2.521
##                      Mean   :2.508
##                      3rd Qu.:3.761
##                      Max.   :5.000
##      TSH_Result      T4_Result      T3_Result      Cancer
## Min.   : 0.100      Min.   : 4.500      Min.   :0.500      Min.   :0.00
## 1st Qu.: 2.583      1st Qu.: 6.372      1st Qu.:1.255      1st Qu.:0.00
## Median : 5.059      Median : 8.237      Median :2.004      Median :0.00
## Mean   : 5.057      Mean   : 8.249      Mean   :2.005      Mean   :0.12
## 3rd Qu.: 7.542      3rd Qu.:10.127      3rd Qu.:2.758      3rd Qu.:0.00
## Max.   :10.000      Max.   :12.000      Max.   :3.500      Max.   :1.00
```

기초 통계량을 통해 각 변수의 최소값, 최대값, 평균 및 사분위수를 확인하였다. 이를 통해 변수의 전체적인 분포를 파악할 수 있었다.

결측치

```
na_df <- data.frame(
  Variable=names(train),
  Missing=colSums(is.na(train))
)


kable(na_df)
```

	Variable	Missing
ID	ID	0
Age	Age	0
Gender	Gender	0
Country	Country	0
Race	Race	0
Family_Background	Family_Background	0
Radiation_History	Radiation_History	0
Iodine_Deficiency	Iodine_Deficiency	0
Smoke	Smoke	0
Weight_Risk	Weight_Risk	0
Diabetes	Diabetes	0
Nodule_Size	Nodule_Size	0
TSH_Result	TSH_Result	0
T4_Result	T4_Result	0
T3_Result	T3_Result	0
Cancer	Cancer	0

모든 변수에서 결측치가 발견되지 않았으며, 결측치 처리 과정은 필요하지 않은 것으로 판단하였다.

클래스(target)분포

```
ggplot(train, aes(x = factor(Cancer))) +
  geom_bar(fill = "steelblue") +
  geom_text(stat = "count",
            aes(label = after_stat(count)),
            vjust = -0.3) +
  labs(
    title = "Cancer Class Distribution",
    x = "Cancer",
    y = "Count"
  )
```



Cancer 클래스는 약 88:12의 비율을 보여 클래스 불균형이 존재하였다. 향후 모델 학습 시 이를 고려한 평가 및 학습 방법이 필요할 것으로 판단된다.

```
prop.table(table(train$Cancer)) * 100
```

```
##
##      0      1
## 88.00009 11.99991
```

Cancer 클래스는 약 88%와 12%의 비율로 분포하여 클래스 불균형이 존재함을 확인하였다.

범주형 변수 분포

```
cat_cols <- c(
  "Gender",
  "Country",
  "Race",
  "Family_Background",
  "Radiation_History",
  "Iodine_Deficiency",
  "Smoke",
```


```


    "Weight_Risk",
    "Diabetes"
)


for(col in cat_cols){


  print(
    ggplot(train, aes(x = .data[[col]])) +
    geom_bar(fill = "forestgreen") +
    labs(title = col) +
    theme(axis.text.x = element_text(angle = 45, hjust = 1))
  )
}


```























범주형 변수의 분포를 확인한 결과 변수마다 각 범주의 비율이 서로 다르게 나타났다.


수치형 변수 분포(Histogram)


```
num_cols <- c(
  "Age",
  "Nodule_Size",
  "TSH_Result",
  "T4_Result",
  "T3_Result"
)


for(col in num_cols){


  print(
    ggplot(train, aes(x = .data[[col]])) +
    geom_histogram(
      bins = 30,
      fill = "skyblue",
      color = "white"
    ) +
    labs(title = paste(col, "Distribution"))
  )
}
```


```
)  
}
```












수치형 변수의 분포를 확인한 결과 변수별로 서로 다른 분포 형태를 보였다. 일부 변수는 특정 구간에 값이 집중되는 경향을 확인할 수 있었다.


이상치 확인(Boxplot)


```
for(col in num_cols){


  print(
    ggplot(train, aes(y = .data[[col]])) +
    geom_boxplot(fill = "orange") +
    labs(title = paste(col, "Boxplot"))
  )

}
```










T3_Result Boxplot



```
summary(train[, num_cols])
```

```
##      Age      Nodule_Size      TSH_Result      T4_Result
##  Min.   :14.00   Min.    :0.000   Min.     : 0.100   Min.     : 4.500
## 1st Qu.:32.00   1st Qu.:1.270   1st Qu.: 2.583   1st Qu.: 6.372
## Median :51.00   Median :2.521   Median : 5.059   Median : 8.237
## Mean   :50.86   Mean    :2.508   Mean    : 5.057   Mean    : 8.249
## 3rd Qu.:70.00   3rd Qu.:3.761   3rd Qu.: 7.542   3rd Qu.:10.127
## Max.    :88.00   Max.     :5.000   Max.     :10.000   Max.     :12.000
##   T3_Result
##  Min.    :0.500
## 1st Qu.:1.255
## Median :2.004
## Mean    :2.005
## 3rd Qu.:2.758
## Max.    :3.500
```

```
boxplot.stats(train$Age)$out
```

```
## integer(0)
```



```
length(boxplot.stats(train$Age)$out)
```

```
## [1] 0
```


```
for(col in num_cols){  
  cat(col, ":", length(boxplot.stats(train[[col]])$out), "\n")  
}
```

```
## Age : 0  
## Nodule_Size : 0  
## TSH_Result : 0  
## T4_Result : 0  
## T3_Result : 0
```

수치형 변수의 Boxplot을 통해 데이터의 분포와 이상치 존재 여부를 확인하였다. 분석 결과, Boxplot 기준(IQR 기준)에서 이상치는 관찰되지 않았다.

상관관계 분석(Heatmap)

```
corr <- cor(train[, num_cols])  
  
corrplot(  
  corr,  
  method = "color",  
  type = "upper",  
  addCoef.col = "black"  
)
```



수치형 변수 간 상관관계를 확인한 결과 일부 변수는 약한 상관관계를 보였으며, 전반적으로 매우 높은 상관관계는 관찰되지 않았다.

1-3. 분석결과

EDA를 수행한 결과 다음과 같은 특징을 확인하였다.

- 데이터에는 결측치가 존재하지 않았다.
- Cancer 클래스는 약 88:12의 비율로 불균형하게 분포하였다.
- 일부 수치형 변수에서 이상치가 관찰되었다.
- 수치형 변수 간 상관관계를 확인하였다.
- 범주형 변수는 향후 인코딩이 필요하다.

1-4. 전처리 계획

EDA 결과를 바탕으로 다음과 같은 전처리를 수행할 예정이다.

1. 결측치는 존재하지 않아 별도의 처리를 수행하지 않는다.
2. 범주형 변수는 One-Hot Encoding 또는 Label Encoding을 적용한다.
3. 수치형 변수는 StandardScaler를 이용하여 스케일링을 수행한다.

4. Boxplot 기준에서 이상치가 확인되지 않았으므로 이상치 처리는 수행하지 않을 예정이다.
5. 클래스 불균형을 고려하여 모델 학습 단계에서 Class Weight 또는 SMOTE 적용을 검토한다.

참고문헌

1. R Documentation <https://www.r-project.org/>
2. ggplot2 Documentation <https://ggplot2.tidyverse.org/>
3. DACON 갑상선암 진단 분류 AI 알고리즘 개발 대회 <https://dacon.io/competitions/official/236488>
4. COW AI팀 사전 과제 안내문