

DACON 갑상선암 진단 분류 데이터

탐색적 데이터 분석(EDA) 보고서

2026-2 COW AI팀 사전 과제 · 1주차

1-1. 탐색적 데이터 분석(EDA)이란 무엇이며 왜 수행하는가

EDA의 목적

EDA(탐색적 데이터 분석)란 수집된 데이터를 다양한 각도에서 관찰하고 구조적으로 이해하는 과정이다. 본격적인 데이터 분석에 앞서 그래프나 통계적 기법을 통해 데이터를 직관적으로 파악할 수 있으며, 이를 통해 적절한 데이터 전처리 방식과 최적의 머신러닝 알고리즘을 선정하기 위한 분석 기준을 마련하는 데 목적이 있다.

EDA를 수행해야 하는 이유

- 데이터의 신뢰성 확보:** 결측치, 중복, 이상치 등 데이터 품질 문제를 사전에 발견하여 모델 학습 전에 처리할 수 있다.
- 적절한 전처리 방향 설정:** 각 변수의 스케일과 분포 형태(정규분포/균등분포/치우침 등)를 확인해야 인코딩, 스케일링 등 전처리 방법을 올바르게 선택할 수 있다.
- 클래스 불균형 파악:** 분류 문제에서 타겟 클래스 비율이 불균형하면 정확도(Accuracy)만으로는 모델 성능을 제대로 평가할 수 없으므로, 사전에 불균형 정도를 확인하고 평가 지표 및 리샘플링 전략을 계획해야 한다.
- 변수 간 관계 파악:** 상관관계가 높은 변수, 타겟과 관련이 깊은 변수를 미리 파악하면 불필요한 변수 제거(차원 축소)나 파생 변수 생성(Feature Engineering) 아이디어를 얻을 수 있다.
- 잘못된 가정 방지:** 도메인 지식만으로 데이터를 판단하지 않고, 실제 데이터 분포를 근거로 분석 방향을 설정함으로써 과적합이나 편향된 해석을 줄일 수 있다.

1-2. 데이터 분석 및 시각화

데이터 기본 정보

학습 데이터(train.csv)는 총 **87,159행 × 16개 컬럼**으로 구성되어 있으며, 평가 데이터(test.csv)는 동일한 입력 변수 15개로 구성된다. ID를 제외한 입력 변수는 총 14개이며, 그 중 수치형 변수는 5개 (Age, Nodule_Size, TSH_Result, T4_Result, T3_Result), 범주형 변수는 9개 (Gender, Country, Race, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes)이다. 타겟 변수는 **Cancer** (0: 양성/Benign, 1: 악성/Malignant)이다.

구분	내용
행 수 (train)	87,159
열 수 (train)	16 (ID, 입력변수 14, Cancer)
결측치	전 컬럼 0건 (결측치 없음)
중복 행	0건
수치형 변수	Age, Nodule_Size, TSH_Result, T4_Result, T3_Result
범주형 변수	Gender, Country, Race, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes
타겟 변수	Cancer (이진 분류: 0/1)

각 컬럼의 데이터 분포

수치형 변수 5종의 분포를 히스토그램으로 확인하였다.




그림 1. 수치형 변수(Age, Nodule_Size, TSH_Result, T4_Result, T3_Result) 히스토그램

모든 수치형 변수가 특정 범위 내에서 대체로 균등한(uniform) 분포를 보이고 있다. Age는 14~88세, Nodule_Size는 0~5, TSH_Result는 0.1~10, T4_Result는 4.5~12, T3_Result는 0.5~3.5 범위에 값이 고르게 퍼져 있으며, 실제 의료 데이터에서 흔히 나타나는 정규분포나 오른쪽 치우침(skewed) 형태와는 다른 형태를 보인다.

범주형 변수 9종에 대해서는 각 범주별 빈도를 카운트플롯으로 확인하였다.




그림 2. 범주형 변수 9종의 범주별 빈도 분포

이진 범주형 변수들은 두 범주의 비율이 1:1이 아니라 한쪽으로 치우쳐 있다. Radiation_History(방사선 노출력)는 비노출 85.8% : 노출 14.2%, Smoke(흡연)는 비흡연 80.2% : 흡연 19.8%, Diabetes(당뇨)는 무 80.0% : 유 20.0%, Iodine_Deficiency(요오드 결핍)는 충분 76.1% : 결핍 23.9%, Family_Background(가족력)는 무 71.6% : 유 28.4%, Weight_Risk(비만 위험)는 정상 70.0% : 비만 30.0%로 각각 뚜렷한 쏠림이 있으며, Gender만 여성 59.9% : 남성 40.1%로 비교적 덜 치우친 편이다. Country(10개국)와 Race(5개 인종군)는 최다 범주와 최소 범주 간 비율 차이가 각각 약 3.7배(IND 18.7% vs DEU 5.0%), 3배(CAU 31.1% vs MDE 10.4%) 수준으로 다범주형 변수 중에서도 편차가 존재한다. 반면 앞서 살펴본 수치형 변수 5종(Age, Nodule_Size, TSH_Result, T4_Result, T3_Result)은 정해진 범위 내에서 고르게 퍼진 균등분포 형태를 보였다는 점에서 범주형 변수와 대비된다.

클래스(Target) 분포




그림 3. Cancer(타겟) 클래스 분포 (좌: 개수, 우: 비율)

타겟 변수 Cancer의 분포는 양성(0)이 **76,700건(88.0%)**, 악성(1)이 **10,459건(12.0%)**으로, 약 7.3:1 비율의 뚜렷한 클래스 불균형이 존재한다.

변수 간 상관관계




그림 4. 수치형 변수 및 Cancer 간 피어슨 상관계수 히트맵

수치형 변수 간 상관계수는 모두 ± 0.01 이내로, 서로 뚜렷한 선형 상관관계가 존재하지 않는다. 타겟(Cancer)과의 상관계수 또한 모든 수치형 변수에서 $-0.01 \sim 0.00$ 수준으로 거의 0에 가까워, 수치형 변수 단독으로는 선형적으로 악성 여부를 설명하기 어려운 것으로 보인다.

주요 변수별 시각화

Cancer 클래스에 따른 수치형 변수들의 분포 차이를 박스플롯으로 확인하였다.




그림 5. Cancer 여부에 따른 수치형 변수 박스플롯

양성군과 악성군 사이의 중앙값과 사분위 범위(IQR)가 대부분의 변수에서 뚜렷하게 구분되지 않아, 상관관계 분석 결과와 마찬가지로 수치형 변수 단독으로는 두 그룹을 명확히 구분하기 어려움을 알 수 있다.

범주형 변수 각각에 대해 범주별 악성(Cancer=1) 비율(점선: 전체 평균 12.0%)을 살펴보았다.




그림 6. 범주형 변수 범주별 악성 비율 (점선: 전체 평균)

Family_Background(가족력), Radiation_History(방사선 노출력), Iodine_Deficiency(요오드 결핍), Race(인종), Country(국가)는 범주에 따라 악성 비율이 뚜렷하게 갈리는 반면, Gender, Smoke, Weight_Risk, Diabetes는 범주 간 악성 비율 차이가 거의 없었다. 세부 수치는 아래 표와 같다.

변수	범주	표본 비율	악성 비율
Family_Background	Positive (가족력 있음)	28.4%	17.53%
	Negative (가족력 없음)	71.6%	9.81%
Radiation_History	Exposed (노출)	14.2%	17.98%
	Unexposed (비노출)	85.8%	11.01%
Iodine_Deficiency	Deficient (결핍)	23.9%	16.64%
	Sufficient (충분)	76.1%	10.55%
Race (예시)	ASN (최고)	23.4%	18.60%
	HSP (최저)	15.5%	8.60%
Gender	M	40.1%	12.02%
	F	59.9%	11.98%

표본 비율(해당 범주가 전체에서 차지하는 비중)과 악성 비율(해당 범주 내에서 Cancer=1의 비중)은 서로 다른 개념이다. 예를 들어 Radiation_History의 Exposed는 전체 표본의 14.2%에 불과하지만, 그 안에서의 악성 비율은 17.98%로 Unexposed(11.01%)보다 뚜렷하게 높다.

1-3. 분석 결과

- **데이터 불균형 여부:** 타겟 변수 Cancer는 양성 88.0% : 악성 12.0%로 뚜렷한 클래스 불균형이 존재한다. Accuracy만으로 평가할 경우 다수 클래스(양성)를 예측하는 것만으로도 88%의 정확도가 나올 수 있으므로, Precision, Recall, F1-score, ROC-AUC 등 불균형에 강건한 지표를 함께 사용해야 한다.
- **이상치 존재 여부:** IQR(사분위범위) 기준으로 확인한 결과, 5개 수치형 변수 모두에서 이상치가 검출되지 않았다(0건). 이는 각 변수가 정해진 범위 안에서 균등분포에 가깝게 생성된 데이터의 특성으로 판단되며, 실제 임상 데이터보다는 시뮬레이션/합성 성격이 강한 데이터로 추정된다.
- **상관관계가 높은 변수:** 수치형 변수 간, 그리고 수치형 변수와 타겟 간 상관계수는 모두 0에 가까워 (± 0.01 이내) 뚜렷한 선형 상관관계를 보이는 변수 쌍은 발견되지 않았다. 반면 범주형 변수 중에서는 Family_Background, Radiation_History, Iodine_Deficiency, Race, Country가 Cancer와 비교적 뚜렷한 연관성을 보였고, Gender, Smoke, Weight_Risk, Diabetes는 Cancer와의 연관성이 거의 없는 것으로 나타났다.
- **전처리가 필요한 컬럼:** 범주형 변수 9개는 모델 입력을 위해 인코딩이 필요하며, 특히 Country(10개), Race(5개)와 같이 범주 수가 많은 변수는 인코딩 방식 선택이 중요하다. 수치형 변수 5개는 결측치와 이상치는 없지만 변수 간 스케일(Age: 14~88, TSH_Result: 0.1~10 등)의 단위가 서로 달라 Scaling이 필요하다. ID는 예측에 불필요한 식별자이므로 학습에서 제외해야 한다.

1-4. 전처리 계획

EDA 결과를 바탕으로 2주차에 다음과 같은 전처리를 계획한다.

대상 컬럼	전처리 방법	이유
ID	제거(drop)	단순 식별자로 예측에 기여하지 않으며, 오히려 노이즈나 과적합을 유발할 수 있음
Gender, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes (이진 범주형)	Label Encoding 또는 Binary Mapping	범주가 2개뿐이므로 0/1로 단순 매핑해도 순서·크기 정보 왜곡 없이 표현 가능
Country, Race (다범주형)	One-Hot Encoding (또는 트리 계열 모델 사용 시 Label/Target Encoding 검토)	범주 간 순서가 없는 명목형 변수이므로 원-핫 인코딩이 기본이나, 범주 수가 많아 차원이 늘어나는 점을 고려해 모델에 따라 인코딩 방식을 조정할 계획
Age, Nodule_Size, TSH_Result, T4_Result, T3_Result	Scaling (StandardScaler 또는 MinMaxScaler)	변수마다 값의 범위(단위)가 달라 특정 변수가 거리 기반 모델 등에서 과도한 영향을 주는 것을 방지하기 위함. 이상치가 없으므로 MinMaxScaler와 StandardScaler 모두 적용 가능하며 실험을 통해 비교할 예정
결측치	해당 없음	전 컬럼에서 결측치가 발견되지 않아 별도의 결측치 처리는 불필요
이상치	해당 없음(추가 검증 예정)	IQR 기준 이상치가 검출되지 않았으나, 2주차에 다른 기준(Z-score 등)으로 추가 확인할 예정
클래스 불균형	class_weight 조정, 또는 SMOTE 등 오버샘플링 검토	양성:악성 = 88:12의 불균형으로 인해 모델이 다수 클래스에 편향될 수 있으므로, 3주차 모델링 단계에서 불균형 완화 기법을 적용할 계획
Feature Engineering (선택)	위험 요인 개수 합산 변수 등 파생 변수 생성 검토	Family_Background, Radiation_History, Iodine_Deficiency와 같이 Cancer와 연관성이 높은 범주형 변수들을 조합한 위험도 점수(risk score) 파생 변수를 통해 모델 성능 개선 가능성을 탐색

참고 문헌 (References)

- DAICON, "갑상선암 진단 분류 AI 알고리즘 개발 대회" 대회 상세 페이지, <https://dacon.io/competitions/official/236488/overview/description>
- John W. Tukey, *Exploratory Data Analysis*, Addison-Wesley, 1977.
- Wes McKinney, *Python for Data Analysis*, O'Reilly Media (pandas 공식 문서 <https://pandas.pydata.org/docs/> 참고)
- seaborn 공식 문서, <https://seaborn.pydata.org/>
- scikit-learn 공식 문서 - Preprocessing data, <https://scikit-learn.org/stable/modules/preprocessing.html>