

1. 전처리 방법들에 대해

이전 보고서에서 언급한 컬럼들에 대해 전처리를 적용하기 앞서 결측치 처리, 이상치 처리, 인코딩, Scaling Feature, Engineering 등의 전처리 방법을 알아볼 것이다. 각 방법은 다음과 같다.

결측치 처리 - 데이터 중 비어있는 값인 결측치가 포함된 부분을 처리하는 과정이다

이상치 처리 - 다른 데이터값에 비해 비정상적으로 크거나 작은 값인 이상치를 없애는 과정이지만 의료 데이터에서는 실제 환자의 특성을 나타내는 값이기 때문에 함부로 없애지 않는다.

인코딩 - 컴퓨터가 이해할 수 있도록 문자 형태의 범주형 데이터를 숫자로 변환하는 과정이다.

Scaling - 각 변수의 값의 범위를 비슷한 수준으로 맞춰주는 과정이다.

Feature Engineering - 기존 데이터를 이용해서 머신러닝에 더 유용한 새로운 변수를 만드는 과정으로, 데이터 간의 관계를 이용해서 데이터를 잘 설명해주는 변수를 만들어내는 과정이다.

2. 전처리 적용과 그 결과

이전 보고서에 계획했던 전처리 방법들이 있지만 이번에는 사전과제 안내에 지시된 전처리 방법들이 있기에 위에서 설명한 전처리 방법들을 적용하였다. 각 방법의 결과로 우선 결측치 처리는 주어진 자료데이터에 결측치가 없기에 실제로 적용되지는 않았으나 조언에 따라 결측치 처리 과정을 코드에 삽입하게 되었다. 그 과정으로는 비어있는 값을 중앙값으로 채워넣었으며 그 결과 새 데이터가 추가되어도 원활하게 머신러닝을 수행할 수 있게 되었다. 이상치 처리 과정은 이상치가 실제 환자의 특성을 나타낼 수 있기에 삭제하지 않는게 좋다는 팁과 1주차 보고서에 서술되어있듯이 이렇다할 이상치도 발견되지 않아 아예 적용하지 않았다. 인코딩 과정에서는 문자열로 구분되는 데이터를 컴퓨터가 처리하는데 시간이 걸리고 비효율적이기에 숫자로 변환하기 위해 Gender, Country, Race, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes 등의 컬럼에 적용하였다. 그 방법으로는 가장 자주 쓰이는 one-hot Encoding을 사용하였으며 그 결과 코드를 실행하여 자료파일을 여는데까지 걸리는 시간이 눈에 띄게 줄어들게 되었다. Scaling 과정에서는 각 데이터의 변수값이 가지는 숫자값의 범위가 다르기 때문에 신경망 모델을 사용하기 용이하도록 StandardScaler를 사용하여 값들을 평균과 표준편차에 따라 0에서 1사이의 값으로 변환하였다. 그 결과로 변환된 자료의 값은 그 자체로 쓰이지 않고 머신러닝 모델들이 학습하기 용이한 스케일로 바뀌어지게 되었다. Feature Engineering 방식은 gpt의 도움하에 적용해본 결과 전처리 전후 학습값이 크게 바뀌어졌기 때문에 적용하지 않았으며 3주차 과정중에 적용한 결과와 아닌 결과를 확인하기 위해 주석으로만 남겨두었다.

이상으로 2주차 보고서를 마칩니다.