

데이터 전처리

1-1. 결측치처리

데이터에 빈 칸(값이 없는 곳)을 채우거나 지우는 작업

1-2. 적용한 컬럼

전체 16개 컬럼 (ID, Age, Gender, Country, Race, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes, Nodule_Size, TSH_Result, T4_Result, T3_Result, Cancer) 모두를 대상으로 결측치 여부를 확인

1-3. 적용한 이유

1주차 EDA에서 전체 16개 컬럼 모두 결측치가 0건(0.0%)으로 확인됨. 별도의 결측치 처리가 필요한지 여부를 다시 한 번 명확히 확인하기 위해 재검증

1-4. 적용 방법

df.isnull().sum()으로 전체 컬럼의 결측치 개수를 재확인함.

1-5. 적용 결과

결측치 확인 결과

컬럼	결측치_개수	결측치_비율(%)
ID	0	0.0
Age	0	0.0
Gender	0	0.0
Country	0	0.0
Race	0	0.0
Family_Background	0	0.0
Radiation_History	0	0.0
Iodine_Deficiency	0	0.0
Smoke	0	0.0
Weight_Risk	0	0.0
Diabetes	0	0.0
Nodule_Size	0	0.0
TSH_Result	0	0.0
T4_Result	0	0.0
T3_Result	0	0.0
Cancer	0	0.0

2-1. 이상치 처리

다른 값들과 동떨어진 값을 확인하고 다듬는 작업

2-2. 적용한 컬럼

수치형 변수 5개(Age, Nodule_Size, TSH_Result, T4_Result, T3_Result), 범주형 변수는 IQR 계산이 불가능하므로 대
상에서 제외

2-3. 적용한 이유

1주차 EDA에서 5개 수치형 변수(Age, Nodule_Size, TSH_Result, T4_Result, T3_Result) 모두 IQR 기준 이상치 0건
으로 확인됨. 다만 통계적 이상치와 임상적 이상 신호는 다른 개념이므로, 값을 삭제하는 대신 재확인하는 방식
으로 접근

2-4. 적용 방법

각 수치형 변수에 대해 Q1, Q3, IQR을 계산하고 정상 범위를 벗어나는 값의 개수를 재확인

2-5. 적용 결과

이상치(IQR) 확인 결과

변수	IQR_하한	IQR_상한	이상치_개수
Age	-25.0	127.0	0
Nodule_Size	-2.47	7.5	0
TSH_Result	-4.86	14.98	0
T4_Result	0.74	15.76	0
T3_Result	-1.0	5.01	0

3-1. 인코딩

글자(문자형 데이터)를 컴퓨터가 이해할 수 있는 숫자로 바꾸는 작업. 범주가 2개뿐인 변수는 Label Encoding(0/1)으로, 범주가 여러 개인 변수는 One-Hot Encoding으로 처리하는 것이 일반적

3-2. 적용한 컬럼

Label Encoding: Gender, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, diabetes

One-Hot Encoding: Country(10개 범주), Race(5개 범주)

3-3. 적용한 이유

1주차 EDA 결과 Radiation_History, Iodine_Deficiency, Family_Background 3개 변수가 Cancer와 가장 강하게 유의했던 핵심 변수로 확인. 이 변수들을 포함한 모든 범주형 변수는 모델 학습을 위해 숫자로 변환이 필요.

3-4. 적용 방법 & 3-5. 적용 결과

Sklearn의 LabelEncoding를 사용 / 이 방법은 범주를 알파벳순으로 정렬하여 0, 1을 부여

Label Encoding 매핑 결과 (2개 범주 변수 7개)

컬럼	원본 값	인코딩 후
Gender	F, M	F=0, M=1
Family_Background	Negative, Positive	Negative=0, Positive=1
Radiation_History	Exposed, Unexposed	Exposed=0, Unexposed=1
Iodine_Deficiency	Deficient, Sufficient	Deficient=0, Sufficient=1
Smoke	Non-Smoker, Smoker	Non-Smoker=0, Smoker=1
Weight_Risk	Not Obese, Obese	Not Obese=0, Obese=1
Diabetes	No, Yes	No=0, Yes=1

Pandas의 get_dummies()를 사용 / 범주 각각을 독립된 0/1 컬럼으로 만들어, 순서가 없는 범주형 변수를 숫자 크기 왜곡 없이 표현

One-Hot Encoding 결과 (다범주 변수 2개)

항목	값
원본 컬럼 (Country, Race)	10개 + 5개 = 15개 범주
One-Hot 적용 전 전체 컬럼 수	16
One-Hot 적용 후 전체 컬럼 수	29
증가한 컬럼 수	13

4-1. Scaling

변수마다 다른 숫자의 범위를 비슷한 수준으로 맞춰주는 작업

4-2. 적용한 컬럼

수치형 변수 5개(Age, Nodule_Size, TSH_Result, T4_Result, T3_Result). 인코딩으로 생성된 범주형 파생 컬럼 (Label/One-Hot결과)은 이미 0/1 값이므로 Scaling 대상에서 제외

4-3. 적용한 이유

1주차 EDA 결과 5개 수치형 변수 모두 왜도가 0에 가까운 균일분포 형태로 확인됨. 이런 분포에는 정규분포를 가정하는 변환보다 평균 표준편차 기준으로 맞추는 StandarScaler가 적합함. 또한 변수마다 범위가 크게 달라 (Age 14~88, T3_Result 0.5~3.5) 범위가 큰 변수가 모델 학습에 과대 반영되는 것을 방지하기 위함.

4-4. 적용 방법

Sklearn의 StandardScaler를 사용해 5개 수치형 변수(Age, Nodule_Size, TSH_Result, T4_Result, T3_Result)에 대해 $(값 - 평균) / 표준편차$ 공식으로 변환

4-5. 적용 결과

Scaling 적용 전/후 비교

변수	적용전_평균	적용전_표준편차	적용후_평균	적용후_표준편차
Age	50.86	21.64	0.0	1.0
Nodule_Size	2.51	1.44	0.0	1.0
TSH_Result	5.06	2.86	0.0	1.0
T4_Result	8.25	2.17	0.0	1.0
T3_Result	2.01	0.87	0.0	1.0