



2주차 과제

영역 · 자원	COW
고정하기	☐

다음 전처리 방법에 대해 간략히 설명하고 실제 데이터에 적용

- 결측치 처리
데이터의 Nan 또는 null 값을 채우거나 삭제하는 과정
- 이상치 처리
데이터에서 이상한 값이 있을 경우 값을 대체하거나 삭제하는 과정
- 인코딩
텍스트 데이터를 컴퓨터가 이해할 수 있는 형태로 변환하는 과정
- **Scaling**
서로 다른 변수의 값 범위를 일정한 수준으로 맞추는 과정(수치형)
- **Feature Engineering(선택)**
모델 정확도를 높이기 위해서 주어진 데이터를 예측 모델의 문제를 잘 표현할 수 있는 features로 변형시키는 과정

데이터 전처리의 개념과 중요성 : <https://chaheekwon.tistory.com/entry/데이터-전처리의-개념과-중요성>

<https://day-to-day.tistory.com/39>

각 전처리에 대해

- 적용한 이유
- 적용 방법
- 적용 결과

를 함께 작성

1. 불필요 컬럼 제거 (Column Dropping)

- **duration**: 전 항목 결측치(NaN)로 구성되어 유효한 정보가 없으므로 삭제
- **rating**: vote_average 변수와 수치가 완벽히 동일한 중복 데이터이므로 다중공선성 방지를 위해 삭제
- **description**: 비정형 텍스트 설명 피처로 수치/범주형 예측 모델 입력 데이터로 부적합하여 삭제
- **type**: 모든 데이터가 'movie' 단일 범주값으로 구성되어 변별력이 없으므로 삭제

2. 데이터 필터링 및 타겟 변수 생성 (Target Generation)

- **데이터 정제**: 제작비 정보가 미비한 데이터 제외를 위해 budget > 0 조건의 유효 데이터셋 구축
- **타겟 변수(is_profitable) 정의**: 영화 산업의 정산 구조(극장 수수료 50%, 부가가치세 및 기금 10% 등)를 반영하여, 박스오피스 매출(revenue)이 제작비(budget) 대비 2.0배 이상인 경우 1(BEP 달성), 2.0배 미만인 경우 0으로 설정

3. 이상치 처리 및 스케일링 (Outlier & Log Transformation)

- **로그 변환(`np.log1p`) 적용**: IQR 기준 상한 이상치 비율이 높고 우측 비대칭 편향(Right-skewed)이 심한 주요 수치형 변수에 대해 정보 손실 없는 분포 정규화 및 스케일 완화를 목적으로 수행
 - **budget**: 이상치 579개 (11.95%) $\rightarrow$ `budget_log` 변환
 - **popularity**: 이상치 521개 (10.75%) $\rightarrow$ `popularity_log` 변환
 - **vote_count**: 이상치 536개 (11.06%) $\rightarrow$ `vote_count_log` 변환
- **로그 변환 제외**: **vote_average**는 값의 범위가 0~10점으로 한정되어 있고 이상치 비율(3.24%)이 낮아 원본 수치 유지

4. 범주형 변수 인코딩 (Categorical Feature Encoding)

- **genres (장르)**: 1개 영화-다중 장르 구조를 해소하기 위해 Multi-label One-Hot Encoding을 적용하여 20개의 이진 가변수(0/1) 피처 생성
- **language (언어)**: 영어(en) 비중이 72% 이상으로 극심하게 편중된 특성을 고려하여 상위 5개 주요 언어(en, fr, es, hi, zh) 외 나머지를 'Other'로 범주화한 후 원-핫 인코딩 수행 (총 6개 피처 생성)
- **country (제작국)**: 복수 국가 합작 구조 해소 및 차원 축소를 위해 전체 데이터의 89.8%를 커버하는 상위 10개국을 선별하여 Multi-label One-Hot Encoding 수행 (Top 10 + country_Other, 총 11개 피처 생성)