

2주차 데이터 전처리 보고서

이상민

2026-08-11

2주차 데이터 전처리 보고서

1. 데이터 전처리 개요

데이터 전처리는 머신러닝 모델이 데이터를 효과적으로 학습할 수 있도록 데이터의 결측값, 이상치, 자료형 및 변수의 표현 방식을 확인하고 필요한 변환을 수행하는 과정이다.

본 과제에서는 DACON 갑상선암 진단 분류 데이터를 대상으로 데이터 전처리를 수행하였다. 1주차 탐색적 데이터 분석(EDA) 결과를 바탕으로 결측치 처리, 이상치 처리, 범주형 변수 인코딩, 수치형 변수 Scaling을 진행하였다. Feature Engineering의 경우 추가적인 파생변수 생성의 필요성을 검토한 후 적용하지 않았다.

2. 데이터 확인

Train 데이터는 **87,159개의 관측치와 16개의 변수**, Test 데이터는 **46,204개의 관측치와 15개의 변수**로 구성되어 있다.

주요 변수는 다음과 같다.

- 수치형 변수: Age, Nodule_Size, TSH_Result, T4_Result, T3_Result
- 범주형 변수: Gender, Country, Race, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes
- 식별자: ID
- Target: Cancer

Cancer는 예측 대상 변수로 사용하였으며, ID는 각 데이터를 구분하기 위한 식별자이므로 모델 입력 변수에서 제외하였다.

3. 결측치 처리

3.1 적용 이유

결측치는 데이터 분석 및 머신러닝 모델 학습 과정에서 문제를 발생시킬 수 있으므로, 각 변수에 결측값이 존재하는지 확인하였다.

3.2 적용 방법

R의 `is.na()`와 `colSums()`를 이용하여 Train과 Test 데이터의 변수별 결측치 개수를 확인하였다.

```
# Train
colSums(is.na(train))
```

```
##           ID           Age           Gender           Country
##           0           0           0           0
##      Race Family_Background Radiation_History Iodine_Deficiency
##           0           0           0           0
##      Smoke      Weight_Risk      Diabetes      Nodule_Size
##           0           0           0           0
##      TSH_Result      T4_Result      T3_Result      Cancer
##           0           0           0           0
```

```
# Test
colSums(is.na(test))
```

```
##           ID           Age           Gender           Country
##           0           0           0           0
##      Race Family_Background Radiation_History Iodine_Deficiency
##           0           0           0           0
##      Smoke      Weight_Risk      Diabetes      Nodule_Size
##           0           0           0           0
##      TSH_Result      T4_Result      T3_Result
##           0           0           0
```

```
#
sum(is.na(train))
```

```
## [1] 0
```

```
sum(is.na(test))
```

```
## [1] 0
```

3.3 적용 결과

확인 결과 Train과 Test 데이터의 모든 변수에서 결측치가 발견되지 않았다.

따라서 평균이나 중앙값을 이용한 결측치 대체 또는 결측 행 삭제 등의 별도 처리를 수행하지 않았다.

결과 요약

데이터	전체 결측치
Train	0
Test	0

4. 이상치 처리

4.1 적용 이유

수치형 변수에 극단적인 값이 존재하는 경우 통계적 분석이나 이후 머신러닝 모델의 학습에 영향을 줄 가능성이 있으므로 이상치 여부를 확인하였다.

대상 수치형 변수는 다음과 같다.

- Age
- Nodule_Size
- TSH_Result
- T4_Result
- T3_Result

4.2 적용 방법

이상치 확인에는 **IQR(Interquartile Range) 방법**을 사용하였다.

IQR은 제3사분위수(Q3)에서 제1사분위수(Q1)를 뺀 값이며, 다음 기준을 이용하여 이상치를 판단하였다.

$$IQR = Q3 - Q1$$

$$= Q1 - 1.5 \times IQR$$

$$= Q3 + 1.5 \times IQR$$

하한보다 작거나 상한보다 큰 값을 이상치로 정의하였다.

```
num_cols <- c(
  "Age",
  "Nodule_Size",
  "TSH_Result",
  "T4_Result",
  "T3_Result"
)

outlier_count <- sapply(train[num_cols], function(x) {
  Q1 <- quantile(x, 0.25)
  Q3 <- quantile(x, 0.75)
  IQR_value <- Q3 - Q1

  lower <- Q1 - 1.5 * IQR_value
  upper <- Q3 + 1.5 * IQR_value

  sum(x < lower | x > upper)
})

outlier_count
```

```
##      Age Nodule_Size TSH_Result T4_Result T3_Result
##      0           0           0           0           0
```

4.3 적용 결과

IQR 기준으로 이상치 개수를 확인한 결과, 모든 수치형 변수에서 이상치가 발견되지 않았다.

변수	이상치 개수
Age	0
Nodule_Size	0
TSH_Result	0
T4_Result	0
T3_Result	0

따라서 이상치 제거 또는 대체를 별도로 수행하지 않았다.

5. 범주형 변수 인코딩

5.1 적용 이유

범주형 변수는 문자 형태로 저장되어 있기 때문에 머신러닝 모델에서 사용할 수 있는 수치 형태로 변환할 필요가 있다.

데이터 확인 결과 다음 9개 변수를 범주형 변수로 확인하였다.

- Gender
- Country
- Race
- Family_Background
- Radiation_History
- Iodine_Deficiency
- Smoke
- Weight_Risk
- Diabetes

5.2 적용 방법

먼저 범주형 변수를 factor로 변환하였다.

```
categorical_cols <- c(  
  "Gender",  
  "Country",  
  "Race",  
  "Family_Background",  
  "Radiation_History",  
  "Iodine_Deficiency",  
  "Smoke",  
  "Weight_Risk",  
  "Diabetes"  
)
```

```
train[categorical_cols] <-
  lapply(train[categorical_cols], factor)

test[categorical_cols] <-
  lapply(test[categorical_cols], factor)
```

이후 `model.matrix()`를 이용하여 One-Hot Encoding을 적용하였다.

```
encoded_train <- model.matrix(
  ~ . - 1,
  data = train[categorical_cols]
)

encoded_test <- model.matrix(
  ~ . - 1,
  data = test[categorical_cols]
)

dim(encoded_train)
```

```
## [1] 87159    21
```

```
dim(encoded_test)
```

```
## [1] 46204    21
```

또한 Train과 Test의 범주를 비교하여 Test에만 존재하는 새로운 범주가 있는지 확인하였다.

```
lapply(categorical_cols, function(col) {
  setdiff(unique(test[[col]]), unique(train[[col]]))
})
```

```
## [[1]]
## factor()
## Levels: F M
##
## [[2]]
## factor()
## Levels: BRA CHN DEU GBR IND JPN KOR NGU RUS USA
##
## [[3]]
## factor()
## Levels: AFR ASN CAU HSP MDE
##
## [[4]]
## factor()
## Levels: Negative Positive
##
## [[5]]
## factor()
## Levels: Exposed Unexposed
```

```
##
## [[6]]
## factor()
## Levels: Deficient Sufficient
##
## [[7]]
## factor()
## Levels: Non-Smoker Smoker
##
## [[8]]
## factor()
## Levels: Not Obese Obese
##
## [[9]]
## factor()
## Levels: No Yes
```

확인 결과 Test에만 존재하는 새로운 범주는 발견되지 않았다.

5.3 적용 결과

One-Hot Encoding을 적용한 결과 범주형 변수들이 0과 1로 표현되는 수치형 변수로 변환되었다.

Train 데이터에서는 총 **21개의 인코딩 변수**가 생성되었다.

따라서 최종 Train 데이터는 다음과 같이 구성하였다.

- 수치형 변수: 5개
- One-Hot Encoding 변수: 21개
- Target Cancer: 1개

총 **27개 변수**로 구성된다.

ID는 식별자이므로 최종 모델 입력에서 제외하였다.

6. Scaling

6.1 적용 이유

수치형 변수마다 측정 범위가 서로 다르기 때문에 변수 간 스케일 차이가 모델 학습에 영향을 줄 수 있다.

전처리 전 수치형 변수의 범위는 다음과 같다.

변수	최소값	최대값
Age	14	88
Nodule_Size	0	5
TSH_Result	0.1	10
T4_Result	4.5	12
T3_Result	0.5	3.5

변수	최소값	최대값
----	-----	-----

따라서 5개의 수치형 변수에 Standardization을 적용하였다.

6.2 적용 방법

Train 데이터에서 각 변수의 평균과 표준편차를 계산한 후 이를 기준으로 표준화하였다.

```
train_means <- sapply(train[num_cols], mean)
train_sds <- sapply(train[num_cols], sd)

scaled_train_num <- scale(
  train[num_cols],
  center = train_means,
  scale = train_sds
)

scaled_test_num <- scale(
  test[num_cols],
  center = train_means,
  scale = train_sds
)
```

Test 데이터에는 Test 자체의 평균과 표준편차를 사용하지 않고 **Train 데이터에서 계산된 평균과 표준편차를 그대로 사용하였다.**

이를 통해 Train과 Test에 동일한 기준의 Scaling을 적용하였다.

6.3 적용 결과

Scaling 결과 Train 데이터의 수치형 변수는 평균이 0에 가깝고 표준편차가 1에 가까운 형태로 변환되었다.

```
colMeans(scaled_train_num)
```

```
##           Age  Nodule_Size  TSH_Result  T4_Result  T3_Result
## 1.371974e-16 -2.157776e-16  1.715694e-16 -2.802517e-16  1.087893e-16
```

```
apply(scaled_train_num, 2, sd)
```

```
##           Age Nodule_Size  TSH_Result  T4_Result  T3_Result
##           1           1           1           1           1
```

실제 확인 결과 평균은 모두 0에 매우 가까운 값으로 나타났으며, 표준편차는 모두 1에 매우 가까운 값으로 나타났다. 따라서 수치형 변수의 Standardization이 정상적으로 수행되었음을 확인하였다.

7. Feature Engineering

7.1 적용 여부

이번 전처리에서는 추가적인 Feature Engineering을 수행하지 않았다.

7.2 판단 이유

현재 데이터에는 분석에 사용할 수 있는 수치형 변수와 범주형 변수가 충분히 존재하며, 결측치 및 이상치 분석을 통해 별도의 데이터 보정이 필요하지 않음을 확인하였다.

또한 임의의 변수 조합이나 단순한 합산을 통해 새로운 변수를 생성할 경우 기존 변수의 의미를 왜곡할 가능성이 있다고 판단하였다.

따라서 이번 단계에서는 기존 변수의 정보를 유지하고 추가적인 파생변수를 생성하지 않았다.

8. 최종 전처리 결과

앞선 전처리 과정을 모두 적용한 후 Train과 Test 데이터를 최종적으로 구성하였다.

```
train_processed <- data.frame(  
  scaled_train_num,  
  encoded_train,  
  Cancer = train$Cancer  
)  
  
test_processed <- data.frame(  
  scaled_test_num,  
  encoded_test  
)  
  
dim(train_processed)
```

```
## [1] 87159    27
```

```
dim(test_processed)
```

```
## [1] 46204    26
```

최종 데이터의 크기는 다음과 같다.

데이터	행	열
Train	87,159	27
Test	46,204	26

최종 Train 데이터에서 결측치가 다시 발생하지 않았는지도 확인하였다.


```
colSums(is.na(train_processed))
```

```
##           Age           Nodule_Size
##           0           0
##      TSH_Result      T4_Result
##           0           0
##      T3_Result      GenderF
##           0           0
##      GenderM      CountryCHN
##           0           0
##      CountryDEU      CountryGBR
##           0           0
##      CountryIND      CountryJPN
##           0           0
##      CountryKOR      CountryNGA
##           0           0
##      CountryRUS      CountryUSA
##           0           0
##      RaceASN      RaceCAU
##           0           0
##      RaceHSP      RaceMDE
##           0           0
## Family_BackgroundPositive Radiation_HistoryUnexposed
##           0           0
## Iodine_DeficiencySufficient      SmokeSmoker
##           0           0
##      Weight_RiskObese      DiabetesYes
##           0           0
##           Cancer
##           0
```

확인 결과 모든 변수에서 결측치가 0개로 나타났다.

9. 전처리 결과 요약

전처리 항목	적용 방법	적용 결과
결측치 처리	<code>is.na()</code> , <code>colSums()</code>	결측치 없음
이상치 처리	$IQR \times 1.5$	이상치 없음
인코딩	One-Hot Encoding	21개 변수 생성
Scaling	Standardization	평균 ≈ 0 , 표준편차 ≈ 1
Feature Engineering	검토 후 미적용	기존 변수 유지

10. 결론

본 과제에서는 머신러닝 모델 학습에 앞서 데이터의 품질과 변수의 형태를 확인하고 필요한 전처리를 수행하였다.

결측치 확인 결과 Train과 Test 모두 결측치가 존재하지 않았으며, 수치형 변수에 대한 IQR 기반 이상치 분석에서도 이상치가 발견되지 않았다. 따라서 결측치 대체나 이상치 제거는 수행하지 않았다.

범주형 변수는 One-Hot Encoding을 통해 수치형 변수로 변환하였으며, 수치형 변수 5개에는 Train 데이터를 기준으로 Standardization을 적용하였다. Test 데이터에는 Train에서 계산된 평균과 표준편차를 동일하게 적용하여 전처리 기준을 일관되게 유지하였다.

최종적으로 Train 데이터는 **87,159개 행, 27개 변수**, Test 데이터는 **46,204개 행, 26개 변수**로 구성되었으며, 이후 머신러닝 모델 학습에 사용할 수 있는 형태로 전처리를 완료하였다.

참고 자료

1. **2026-2 COW AI팀 사전 과제**
2주차 데이터 전처리 과제 안내
2. **R Documentation - NA / Missing Values**
<https://stat.ethz.ch/R-manual/R-patched/RHOME/library/base/html/NA.html>
3. **R Documentation - Sample Quantiles**
<https://www.stat.ethz.ch/R-manual/R-devel/library/stats/html/quantile.html>
4. **R Documentation - Construct Design Matrices**
<https://stat.ethz.ch/R-manual/R-devel/RHOME/library/stats/html/model.matrix.html>
5. **R Documentation - Scaling and Centering**
<https://stat.ethz.ch/R-manual/R-devel/library/base/html/scale.html>