

DACON 갑상선암 진단 분류 데이터

데이터 전처리 보고서

2026-2 COW AI팀 사전 과제 · 2주차

1주차 EDA 요약

- 결측치: 전 컬럼 0건 / 중복 행: 0건
- IQR 기준 이상치: 전 수치형 변수 0건 (변수들이 특정 범위 내 균등분포에 가까움)
- 타겟(Cancer) 불균형: 양성(0) 88.0% / 악성(1) 12.0%
- Family_Background, Radiation_History, Iodine_Deficiency, Race, Country가 악성 비율과 뚜렷한 연관성을 보임

결측치 처리

전처리 방법 설명

결측치 처리는 데이터에 비어 있는 값을 채우거나(대체, Imputation) 해당 행/열을 제거하는 작업이다. 결측 비율이 매우 낮으면 행 제거를, 결측 비율이 높으면 평균·중앙값·최빈값 대체나 예측 모델 기반 대체를 고려하며, 결측 자체가 의미 있는 정보인 경우 별도의 '결측' 범주를 만들기도 한다.

적용 이유

1주차 EDA에서 train, test 데이터 모두 전 컬럼에 결측치가 없음을 확인하였다.

적용 방법

`train.isnull().sum()`, `test.isnull().sum()` 으로 결측치 여부를 재확인하였다.

적용 결과

train, test 모두 결측치 합계가 **0건**으로 확인되어, 별도의 결측치 대체·제거 작업을 수행하지 않았다.

이상치 처리

전처리 방법 설명

이상치(Outlier)는 다른 관측치들과 크게 동떨어진 값으로, 특히 거리 기반·선형 모델의 학습을 왜곡할 수 있다. 대표적인 탐지 방법은 ① **IQR 기준**($Q1 - 1.5 \times IQR \sim Q3 + 1.5 \times IQR$ 범위를 벗어나는 값), ② **Z-score 기준**(평균에서 표준편차의 3배 이상 벗어난 값)이 있으며, 발견된 이상치는 제거하거나 상/하한값으로 대체(Capping)하는 방법이 흔히 사용된다.

적용 이유

1주차에는 IQR 기준만 확인하였으므로, 2주차에서는 Z-score 기준을 추가로 적용하여 교차 검증하였다.

적용 방법

수치형 변수 5종(Age, Nodule_Size, TSH_Result, T4_Result, T3_Result)에 대해 `scipy.stats.zscore` 로 Z-score를 계산하고, $|z| > 3$ 인 값을 이상치로 집계하였다.

적용 결과

변수	Z-score 이상치 개수	비율
Age	0	0.000%
Nodule_Size	0	0.000%
TSH_Result	0	0.000%
T4_Result	0	0.000%
T3_Result	0	0.000%

T3_Result	0	0.000%
-----------	---	--------

IQR, Z-score 두 기준 모두에서 이상치가 전혀 검출되지 않았다. 이는 수치형 변수들이 특정 범위 내에서 균등분포에 가깝게 생성되어 있기 때문으로 판단되며, 별도의 이상치 제거·대체 작업은 수행하지 않았다.

인코딩(Encoding)

전처리 방법 설명

머신러닝 모델은 문자열(범주형) 데이터를 직접 학습할 수 없으므로 숫자로 변환하는 인코딩이 필요하다. 범주가 2개인 변수는 **Binary Encoding**(0/1 단순 매핑)을 적용해도 순서·크기 정보의 왜곡이 없지만, 범주가 3개 이상이고 순서가 없는 명목형 변수에 Label Encoding을 적용하면 모델이 범주 사이에 없는 크기·순서 관계를 학습할 위험이 있어 **One-Hot Encoding**을 사용하는 것이 일반적이다.

적용 이유

이진 범주형 변수(Gender, Family_Background, Radiation_History, Iodine_Deficiency, Smoke, Weight_Risk, Diabetes) 7개는 범주가 2개뿐이므로 Binary Encoding을 적용하였다. 다범주형 변수인 Country(10개국), Race(5개 인종군)는 순서가 없는 명목형 변수이므로 One-Hot Encoding을 적용하였다.

적용 방법

이진 변수는 train 데이터 기준으로 범주를 정렬하여 {범주: 0/1} 매핑을 만들고 train/test에 동일하게 적용하였다. 다범주형 변수는 sklearn.preprocessing.OneHotEncoder를 train 데이터에 fit한 뒤 train/test에 동일하게 transform하여, 두 데이터셋의 인코딩 결과가 항상 같은 기준으로 일치하도록 하였다.

변수	매핑
Gender	F → 0, M → 1
Family_Background	Negative → 0, Positive → 1
Radiation_History	Exposed → 0, Unexposed → 1
Iodine_Deficiency	Deficient → 0, Sufficient → 1
Smoke	Non-Smoker → 0, Smoker → 1
Weight_Risk	Not Obese → 0, Obese → 1
Diabetes	No → 0, Yes → 1

적용 결과

인코딩 이전 16개였던 train 컬럼 수(ID, Cancer 포함)가 인코딩 이후 **29개**로 확장되었다 (Country 10개 + Race 5개 One-Hot 컬럼이 새로 생성되고 원본 두 컬럼은 제거됨). train과 test의 컬럼 구성을 비교한 결과 완전히 일치함을 확인하였다.

Scaling

전처리 방법 설명

Scaling은 변수마다 다른 값의 범위(단위)를 동일한 척도로 맞추는 작업이다. 특히 거리 기반 모델(KNN, SVM)이나 경사하강법 기반 모델(로지스틱 회귀, 신경망)은 변수 간 스케일 차이가 크면 특정 변수가 과도한 영향을 미칠 수 있다. 평균 0, 표준편차 1로 변환하는 **StandardScaler**와 최소값 0, 최대값 1로 변환하는 **MinMaxScaler**가 대표적이며, 이상치가 많을 경우 중앙값과 IQR을 사용하는 **RobustScaler**가 유리하다.

적용 이유

수치형 변수 5종은 값의 범위(단위)가 서로 다르고(Age: 14~88, TSH_Result: 0.1~10 등), 앞서 확인했듯 이상치가 거의 없어 이상치에 민감하지 않은 **StandardScaler**를 적용하였다.

적용 방법

train 데이터의 수치형 변수 5종에 StandardScaler를 fit한 뒤, 동일한 스케일러로 train/test를 transform하였다(test는 fit에 사용하지 않아 데이터 누수를 방지함).




그림 1. Scaling 이후 수치형 변수 5종의 분포

적용 결과

변수	평균	표준편차	최소값	최대값
Age	0.000	1.000	-1.703	1.716
Nodule_Size	-0.000	1.000	-1.739	1.728
TSH_Result	-0.000	1.000	-1.732	1.728
T4_Result	0.000	1.000	-1.731	1.732
T3_Result	0.000	1.000	-1.736	1.724

Scaling 이후 모든 수치형 변수의 평균이 0, 표준편차가 1로 통일되었다. 분포의 형태(균등분포) 자체는 그대로 유지된 채 값의 범위만 조정되어, 변수 간 스케일 차이로 인한 편향 없이 모델에 투입할 수 있게 되었다.

Feature Engineering (선택)

적용 이유

1주차 EDA에서 Family_Background(가족력), Radiation_History(방사선 노출력), Iodine_Deficiency(요오드 결핍)는 각각 양성 대비 악성 비율이 뚜렷하게 높았다(전체 평균 12.0% 대비 각각 17.53%, 17.98%, 16.64%). 이 세 위험 요인을 개별 변수로 따로 두는 것보다, 한 사람이 위험 요인을 몇 개나 동시에 가지고 있는지를 나타내는 **위험도 점수(Risk_Score)** 파생 변수를 만들면 위험 요인의 '누적 효과'를 모델이 더 직접적으로 학습할 수 있을 것이라는 아이디어로 생성하였다.

적용 방법

인코딩 이전의 원본 범주를 기준으로 Family_Background=Positive, Radiation_History=Exposed, Iodine_Deficiency=Deficient 여부를 각각 0/1로 판정한 뒤 세 값을 합산하여 0~3 사이의 정수형 Risk_Score를 생성하고, train과 test에 동일한 기준으로 적용하였다.




그림 2. Risk_Score(위험 요인 개수)별 악성 비율

적용 결과

Risk_Score	악성 비율
0 (위험 요인 없음)	7.2%
1	14.6%
2	20.7%
3 (위험 요인 모두 해당)	28.6%

Risk_Score가 0에서 3으로 증가할수록 악성 비율이 **7.2% → 14.6% → 20.7% → 28.6%**로 단조적으로 증가하는 뚜렷한 경향을 보였다. 개별 위험 요인 변수만으로는 드러나지 않았던 '위험 요인이 누적될수록 악성 위험이 커진다'는 관계가 이 파생 변수를 통해 명확하게 드러났으며, 3주차 모델링에서 중요한 변수로 활용될 것으로 기대한다.

전처리 결과 정리

항목	전처리 전	전처리 후
train 컬럼 수	16 (ID, 입력변수 14, Cancer)	30 (ID, 입력변수 28, Cancer, Risk_Score 포함)
결측치	0건	해당 없음(처리 불필요)
이상치	0건(IQR/Z-score)	해당 없음(처리 불필요)
범주형 변수	문자열 9개	이진 인코딩 7개 + One-Hot 15개(Country 10 + Race 5)
수치형 변수	원본 스케일 5개	StandardScaler 적용 5개
파생 변수	-	Risk_Score(0~3) 1개 추가

전처리가 완료된 데이터셋은 `train_preprocessed.csv` , `test_preprocessed.csv` 로 저장하여 3주차 모델 학습에 그대로 활용할 수 있도록 하였다.

참고 문헌 (References)

- DAICON, "갑상선암 진단 분류 AI 알고리즘 개발 대회" 대회 상세 페이지, <https://dacon.io/competitions/official/236488/overview/description>
- scikit-learn 공식 문서 - Preprocessing data, <https://scikit-learn.org/stable/modules/preprocessing.html>
- scikit-learn 공식 문서 - OneHotEncoder, <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html>
- SciPy 공식 문서 - scipy.stats.zscore, <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.zscore.html>