

### 1.머신러닝 이론에 대하여

지금까지 언급하고, 또 사용했던 머닝러닝이란, 컴퓨터가 사람이 일일이 규칙을 프로그래밍하지 않아도 데이터를 학습하여 패턴이나 규칙을 찾아내고, 새로운 데이터에 대해 예측이나 판단을 수행하는 기술로 정의되어있다. 데이터 수집 → 전처리 → 학습 → 모델 생성 → 새로운 데이터 예측의 과정으로 이루어져있으며 크게 분류와 회귀의 종류가 있다.

둘은 예측하려는 결과가 무엇이나에 따라서 알맞게 사용된다. 분류는 이름 그대로 데이터가 각각 어떤 범주에 속하는지 분류한 결과를 얻으려 할 때 사용되며, 회귀는 연속적인, 다시말해 정확한 수치, 값이 얼마나 되는지 예측한 결과를 얻으려 할 때 사용된다. 둘의 대표적인 모델은 로지스틱 회귀, 결정 트리, SVM등의 분류방식을 사용하는 모델과, 선형 회귀, 결정 트리, 랜덤 포레스트 등의 회귀방식을 사용하는 모델이 있다.

위 모델중에서도 대표적인 모델로는 데이터의 관계를 직선으로 표현하여 연속적인 값을 예측하는 모델이자 회귀모델인 선형회귀, 데이터를 여러 가지 질문으로 나누어 가면서 결과를 예측하는 모델이며 분류와 회귀 모두 사용 가능한 결정트리, 여러 개의 결정 트리를 만들고 그 결과를 종합하여 예측하는 모델이며 결정트리와 마찬가지로 분류와 회귀 모두 사용 가능한 랜덤포레스트 모델이 있다. 각각의 대표적 특징으로는 선형회귀모델은 구조가 간단하고 변수와 결과의 관계를 해석하기 쉬워서 이해하기 쉽기에 가장 많이 쓰인다는 특징을 가지고, 결정 트리는 데이터의 전처리가 비교적 간단하면서도 너무 깊게 학습하면 과적합이 발생할 수 있다는 특징이 있으며, 랜덤 포레스트는 과적합을 줄이는 데 효과적이며 비교적 높은 비교적 높은 예측 성능을 얻을 수 있음과 동시에 데이터의 변수 중요도를 따로 확인할 수 있다는 특징이 있다.

### 2.데이터의 분할

머신러닝을 실행하기 위해 필요한 데이터는 크게 학습 데이터와 평가 데이터가 있는데, 학습 데이터란 머신러닝 모델이 패턴과 규칙을 학습하는 데 사용하는 데이터로써 이번 과제에서 사용한 학습 데이터는 인종, 나라 및 기타 신체 데이터를 활용해 어떤 특징을 가진 데이터가 암일 가능성이 높은지 패턴을 찾아가는 등으로 사용되었다. 그리고 평가 데이터란 모델의 학습이 끝난 후 처음 보는 데이터를 얼마나 잘 예측하는지 평가하기 위해 사용하는 데이터이며 전체 데이터 중 일부를 Test 데이터로 따로 보관해 두었다가 학습이 끝난 후 모델에게 보여줘 예측을 시킨 후 정확도를 측정하는데 사용된다. 그렇다면 왜 데이터를 학습용과 평가용으로 나누어 학습시킬까? 가장 중요한 이유는 모델이 새로운 데이터에도 잘 작동하는지 확인하기 위해서이다. 만약 모든 데이터를 학습에 사용하고, 학습에 사용했던 데이터를 다시 평가한다면 모델이 데이터를 외워버린 경우에도 높은 정확도가 나올 수 있다. 이것이 바로 위에서 언급했던 과적합이다. 따라서 데이터 분리의 목적은 크게 모델이 학습 데이터를 단순히 외운 것인지 확인하는 과적합 확인, 모델이 처음 보는 데이터에도 얼마나 잘 예측하는지 확인 등이 있다.

### 3.모델 학습

이번 과제에서 선택한 갑상선 암 환자 분류라는 목적과 데이터를 학습시키기 위한 모델을 고르기 위하여 챗gpt에게 조언을 받은 결과 랜덤 포레스트모델을 사용하는 것이 가장 적합할것으로 보여 선택하게 되었다. 그 이유로는 목적인 Cancer컬럼이 0 또는 1이므로 분류가 가능한 모델이어야하며 Age, Nodule\_Size, TSH\_Result 등 숫자형 데이터와

Gender, Country, Race 등의 범주형 데이터가 함께 있기에 범주형 변수를 One-Hot Encoding한 후 랜덤포레스트에 사용할 수 있고, 암 발생 여부가 하나의 변수에 의해 단순한 직선 관계가 아니기에 변수간 복잡한 관계까지 학습이 가능한 랜덤 포레스트를 사용하였다. 사용할 하이퍼파라미터를 정하는데 조언을 받은결과

|                   |            |                     |
|-------------------|------------|---------------------|
| n_estimators      | 200        | 생성할 결정 트리의 개수       |
| max_depth         | 15         | 각 트리의 최대 깊이         |
| min_samples_split | 5          | 노드를 분할하기 위한 최소 샘플 수 |
| min_samples_leaf  | 2          | 하나의 리프에 필요한 최소 샘플 수 |
| class_weight      | "balanced" | 클래스 불균형 보정          |
| random_state      | 42         | 동일한 결과 재현           |

위의 하이퍼 파라미터들을 사용하였다.

학습 과정으로는 이전에 ID제거, 결측치처리 등 전처리한 데이터를 stratify를 적용하여 Cancer의 0/1 비율이 비슷하게 유지시킨 후, 범주형 변수들에 One-Hot Encoding을 하였다. 이후 위에서 정한 Random Forest의 주요 파라미터를 적용하고 class\_weight="balanced"를 적용하며 트레인 데이터로 학습 후 테스트 데이터를 이용해 테스트를 진행하였다.

#### 4.모델평가

평가는 아래 4개의 평가 지표로 평가되었으며 각 지표의 설명은 다음과 같다.

Accuracy: 전체 데이터 중 맞춘 비율로써 모델이 정확하게 예측한 데이터의 비율이다.

Precision: 암이라고 예측한 것 중 실제 암의 비율이다.

Recall: 실제 암 환자 중 모델이 암이라고 찾아낸 비율이다.

F1-score: Precision과 Recall의 균형, 조화평균으로,  $2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$ 의 식을 사용한다.

각 지표의 결과는 Accuracy가 87.97%가 나왔지만 데이터가 불균형하기에 맹신할수 없으며, Precision은 49.86%, Recall은 43.79%로 실제 암 환자를 상당수 놓치고 있다는 문제를 보여준다. 마지막으로 F1-score은 46.63%이 나왔다. 가장 중요하게 본 지표로는 Recall 지표가 있었으며 Cancer를 예측하는 문제이기 때문에 정상인을 암으로 분류하는것보다 암환자를 정상인으로 분류하는게 더 위험하다 생각하여 Recall을 중요하게 보았다. 이어서 모델이 오분류하는 경우로는 여러 변수들이 동시에 영향을 주고 있기 때문에 하나의 변수만 가지고 암 여부를 명확하게 판단하기 어려운 경우, 암 환자 중에서도 정상 데이터와 특성이 비슷한 사람들이 존재하는 경우, 한마디로 False Negative와 True Positive의 수치형 변수 평균이 매우 비슷한 경우 때문에 오분류가 자주 일어난다고 분석했다. 전체적인 평가로는 Accuracy만 중요하게 보지 않는다면 정확도가 상당히 떨어져 실제 사용하기엔 문제가 있고 개선이 필요하다고 느꼈다.

이상으로 3주차 보고서를 마칩니다.