

3주차 모델 생성, 평가 보고서

이상민

2026-08-15

1. 머신러닝 이론

1.1 머신러닝이란?

머신러닝(Machine Learning)은 데이터를 기반으로 컴퓨터가 데이터에 존재하는 패턴과 관계를 학습하고, 이를 바탕으로 새로운 데이터에 대한 예측이나 판단을 수행하는 방법이다.

본 과제에서는 갑상선암 진단 데이터를 이용하여 환자의 여러 특성으로부터 Cancer 변수가 0(정상)인지 1(암)인지 예측하는 머신러닝 분류 문제를 수행하였다.

1.2 분류와 회귀

머신러닝의 대표적인 문제 유형으로는 분류(Classification)와 회귀(Regression)가 있다.

구분	분류(Classification)	회귀(Regression)
예측 대상	범주형 값	연속형 값
예시	암/정상, 스팸/정상	집값, 매출, 온도
본 과제	해당	해당하지 않음

분류는 입력 데이터를 미리 정의된 여러 범주 중 하나로 분류하는 문제이다. 반면 회귀는 입력 변수들을 이용하여 연속적인 수치값을 예측하는 문제이다.

본 과제의 Cancer 변수는 0과 1의 두 가지 범주로 구성되어 있으므로 **이진 분류(Binary Classification)** 문제에 해당한다.

1.3 대표적인 머신러닝 모델

1.3.1 Logistic Regression

Logistic Regression은 이진 분류 문제에서 널리 사용되는 모델이다. 입력 변수들을 이용하여 특정 클래스에 속할 확률을 계산하고, 이를 기준으로 각 데이터를 분류한다.

또한 각 변수의 계수를 확인할 수 있어 변수와 예측 결과 사이의 관계를 비교적 해석하기 쉽다는 특징이 있다.

본 과제에서는 Cancer가 0 또는 1로 구성된 이진 분류 문제이므로 Logistic Regression을 첫 번째 모델로 선택하였다.

1.3.2 Decision Tree

Decision Tree는 데이터를 특정 조건에 따라 반복적으로 분할하여 예측하는 모델이다. 트리 구조로 결과가 표현되기 때문에 의사결정 과정을 비교적 쉽게 해석할 수 있다는 장점이 있다.

또한 변수와 예측 대상 사이에 비선형적인 관계가 존재하는 경우에도 이러한 관계를 학습할 수 있다.

1.3.3 Random Forest

Random Forest는 여러 개의 Decision Tree를 생성하고 각각의 예측 결과를 결합하여 최종 예측을 수행하는 앙상블 모델이다.

여러 개의 Tree를 이용하기 때문에 단일 Decision Tree보다 안정적인 예측이 가능하며, 변수와 Target 사이의 비선형적인 관계나 변수 간의 상호작용을 학습할 수 있다는 특징이 있다.

본 과제에서는 Logistic Regression의 성능을 확인한 후, 다른 방식으로 데이터를 학습하는 모델을 비교하기 위해 Random Forest를 추가로 사용하였다.

2. 데이터 분할

2.1 Train / Validation 데이터 분할

머신러닝 모델은 학습에 사용한 데이터에 대해서만 평가할 경우 모델이 새로운 데이터에서도 잘 작동하는지를 확인하기 어렵다. 따라서 모델을 학습시키는 데이터와 학습된 모델의 성능을 확인하기 위한 데이터를 분리하였다.

본 과제에서는 2주차에서 전처리가 완료된 `train_processed` 데이터를 다시 학습 데이터와 검증 데이터로 분할하였다.

전체 데이터를 다음과 같이 **80:20 비율**로 나누었다.

- 학습 데이터(Train): 80%
- 검증 데이터(Validation): 20%

또한 Cancer의 클래스 비율이 학습 데이터와 검증 데이터에서 크게 달라지지 않도록 **층화 추출(Stratified Sampling)** 방식을 사용하였다.

2.2 데이터 분할 결과

분할 결과 학습 데이터와 검증 데이터의 크기는 다음과 같다.

데이터	행 수	비율
Train	69,727	약 80%
Validation	17,432	약 20%
전체	87,159	100%

Cancer의 클래스 분포를 확인한 결과 다음과 같이 나타났다.

데이터	Cancer = 0	Cancer = 1
Train	61,360	8,367
Validation	15,340	2,092

각 데이터에서 Cancer=0과 Cancer=1의 비율이 약 88:12로 유사하게 유지되었기 때문에, 층화 추출을 통해 클래스 비율을 고려한 데이터 분할이 이루어진 것을 확인할 수 있었다.

2.3 클래스 불균형

분할 결과 Cancer = 0인 데이터가 약 88%, Cancer = 1인 데이터가 약 12%로 나타났다.

따라서 본 데이터에는 **클래스 불균형(Class Imbalance)**이 존재한다.

이러한 데이터에서는 모든 데이터를 다수 클래스인 Cancer = 0으로 예측하더라도 높은 Accuracy가 나타날 수 있다. 따라서 모델의 성능을 평가할 때 Accuracy만 사용하는 것은 적절하지 않으며, 실제 암 환자를 얼마나 잘 찾아내는지를 나타내는 Recall과 F1-score 등을 함께 확인할 필요가 있다.

3. 모델 학습

3.1 Logistic Regression 모델 선택

본 과제에서는 이진 분류 문제인 Cancer를 예측하기 위해 Logistic Regression을 첫 번째 모델로 선택하였다.

Logistic Regression은 이진 분류 문제에 적합하며, 각 관측치가 Cancer = 1에 속할 확률을 계산할 수 있다는 장점이 있다. 또한 모델의 계수를 통해 각 변수가 예측 결과에 미치는 통계적인 관계를 확인할 수 있다.

2주차 전처리 과정에서 범주형 변수에 대해 One-Hot Encoding을 수행하였기 때문에, 모든 범주 수준을 그대로 사용하기 위해 모델식에서 절편을 제외하였다.

```
logistic_model <- glm(  
  Cancer ~ . - 1,  
  data = model_train,  
  family = binomial  
)
```

family = binomial을 사용하여 Cancer의 이진 분류 문제를 수행하였다.

예측 시에는 모델이 계산한 확률을 기준으로 다음과 같이 클래스를 결정하였다.

- 예측 확률 $\geq 0.5 \rightarrow \text{Cancer} = 1$
- 예측 확률 $< 0.5 \rightarrow \text{Cancer} = 0$

3.2 Logistic Regression 평가 결과

Logistic Regression의 Confusion Matrix는 다음과 같이 나타났다.

실제 / 예측	0	1
0	15,322	18
1	2,072	20

이를 이용하여 계산한 성능 지표는 다음과 같다.

평가 지표	결과
Accuracy	88.01%
Precision	52.63%
Recall	0.96%
F1-score	1.88%

Accuracy는 88.01%로 비교적 높게 나타났지만, Recall은 0.96%로 매우 낮았다.

특히 실제 암 환자 2,092명 중 20명만을 암으로 예측하였으며, **2,072명이 정상으로 잘못 분류되는 False Negative**가 발생하였다.

따라서 본 모델은 Accuracy만 보면 높은 성능을 보이는 것처럼 보이지만, 실제 암 환자를 탐지하는 측면에서는 성능이 매우 낮은 것으로 판단하였다.

3.3 Random Forest 모델 추가 선택 이유

앞서 Logistic Regression을 이용하여 갑상선암 분류 모델을 구축한 결과, Accuracy는 88.01%로 비교적 높게 나타났다.

그러나 Recall은 0.96%, F1-score는 1.88%로 매우 낮았으며, 실제 암 환자 2,092명 중 2,072명을 정상으로 예측하는 False Negative가 발생하였다.

이는 클래스 불균형이 존재하는 상황에서 Logistic Regression의 Accuracy만으로는 모델의 암 탐지 성능을 충분히 판단하기 어렵다는 것을 보여준다.

따라서 Logistic Regression과 다른 방식으로 데이터를 학습하는 모델을 추가하여 성능을 비교하고자 Random Forest를 선택하였다.

Random Forest는 여러 개의 Decision Tree를 결합하는 앙상블 모델로, Logistic Regression과 달리 변수와 Target 사이의 비선형적인 관계를 학습할 수 있다. 또한 여러 변수를 함께 고려하여 변수 간의 상호작용을 반영할 수 있기 때문에 Logistic Regression에서 놓친 패턴을 학습할 수 있는지 확인하기에 적합하다고 판단하였다.

따라서 Random Forest를 추가로 학습한 후 Accuracy, Precision, Recall, F1-score와 Confusion Matrix를 비교하여 두 모델의 성능을 확인하였다.

3.4 Random Forest 모델 학습

Random Forest 모델에서는 다음과 같은 하이퍼파라미터를 설정하였다.

하이퍼파라미터	설정값	의미
ntree	100	생성할 Decision Tree의 개수
mtry	5	각 분할에서 고려할 변수의 개수
importance	TRUE	변수 중요도 계산

모델 학습은 다음과 같이 수행하였다.

```
set.seed(42)

rf_model <- randomForest(
  Cancer ~ .,
  data = rf_train,
  ntree = 100,
  mtry = 5,
  importance = TRUE
)
```

Random Forest 학습 결과, 100개의 Decision Tree가 생성되었으며 각 분할 과정에서 5개의 변수를 후보로 사용하였다.

학습 과정에서 계산된 OOB(Out-of-Bag) 오류율은 **11.84%**로 나타났다.

4. 모델 평가

4.1 평가 지표

본 과제에서는 분류 모델의 성능을 평가하기 위해 Accuracy, Precision, Recall, F1-score를 사용하였다.

Accuracy

전체 데이터 중 모델이 정확하게 예측한 데이터의 비율이다.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Precision

모델이 암이라고 예측한 데이터 중 실제 암인 데이터의 비율이다.

$$Precision = \frac{TP}{TP + FP}$$

Recall

실제 암 환자 중 모델이 암으로 정확하게 예측한 비율이다.

$$Recall = \frac{TP}{TP + FN}$$

본 과제에서는 실제 암 환자를 놓치는 False Negative가 중요하기 때문에 Recall을 특히 중요하게 고려하였다.

F1-score

Precision과 Recall의 조화평균으로, 두 지표를 동시에 고려하는 평가 지표이다.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

4.2 Random Forest 평가 결과

Random Forest의 Confusion Matrix는 다음과 같이 나타났다.

실제 / 예측	0	1
0	15,009	331
1	1,719	373

이를 이용하여 계산한 성능 지표는 다음과 같다.

평가 지표	Logistic Regression	Random Forest
Accuracy	88.01%	88.24%
Precision	52.63%	52.98%
Recall	0.96%	17.83%
F1-score	1.88%	26.68%

4.3 모델 비교

두 모델을 비교한 결과 Random Forest가 Logistic Regression보다 모든 주요 평가 지표에서 개선된 결과를 보였다.

Accuracy는 88.01%에서 88.24%로 소폭 증가하였으며, Precision 역시 52.63%에서 52.98%로 증가하였다.

특히 Recall은 **0.96%에서 17.83%로 크게 증가**하였다. 실제 암 환자 2,092명 중 Logistic Regression은 20명만 암으로 탐지한 반면, Random Forest는 373명을 암으로 탐지하였다.

F1-score 역시 1.88%에서 26.68%로 증가하였다.

따라서 본 과제에서 사용한 두 모델 중에서는 **Random Forest가 Logistic Regression보다 갑상선암 환자를 탐지하는 데 더 적합한 성능을 보였다.**

그러나 Random Forest에서도 실제 암 환자 2,092명 중 1,719명을 정상으로 예측하는 False Negative가 발생하였다. 따라서 Random Forest 역시 실제 암 환자를 충분히 탐지할 수 있는 수준이라고 단정하기는 어렵다.

4.4 오분류 분석

Logistic Regression의 오분류 데이터를 분석한 결과 총 **2,090건**의 오분류가 발생하였다.

이 중 False Positive는 18건이었으며, False Negative는 **2,072건**이었다.

특히 False Negative가 대부분의 오분류를 차지하고 있기 때문에 Logistic Regression은 실제 암 환자를 놓치는 문제가 매우 큰 것으로 확인되었다.

False Negative 집단과 전체 실제 암 환자 집단의 수치형 변수 평균을 비교한 결과는 다음과 같다.

변수	전체 실제 암 환자	False Negative
Age	50.809	50.124
Nodule_Size	2.512	2.515
TSH_Result	4.993	5.063
T4_Result	8.268	8.290
T3_Result	1.997	1.999

각 변수의 평균이 전반적으로 유사하게 나타났기 때문에, 이번 분석만으로는 특정 수치형 변수가 False Negative 발생의 주요 원인이라고 판단하기 어려웠다.

또한 성별, 가족력, 방사선 노출 여부, 요오드 결핍 여부, 흡연 여부, 비만 여부, 당뇨 여부 등 범주형 변수에서도 False Negative가 여러 범주에 걸쳐 나타났다.

따라서 특정 하나의 변수나 범주만으로 오분류의 원인을 설명하기는 어려웠다.

5. 결론

본 과제에서는 갑상선암 데이터를 이용하여 Cancer 변수를 예측하는 이진 분류 문제를 수행하였다.

먼저 데이터를 학습 데이터와 검증 데이터로 80:20 비율로 분할하였으며, Cancer의 클래스 비율이 유지되도록 층화 추출을 적용하였다.

첫 번째 모델로 Logistic Regression을 학습한 결과 Accuracy는 88.01%로 나타났다. 그러나 Recall은 0.96%, F1-score는 1.88%로 매우 낮았으며, 실제 암 환자 2,092명 중 2,072명을 정상으로 분류하는 문제가 확인되었다.

이후 비선형적인 관계와 변수 간 상호작용을 학습할 수 있는 Random Forest를 추가하여 비교하였다. Random Forest의 Accuracy는 88.24%, Precision은 52.98%, Recall은 17.83%, F1-score는 26.68%로 나타났다.

특히 Recall이 크게 개선되어 실제 암 환자를 탐지하는 능력이 Logistic Regression보다 향상된 것을 확인할 수 있었다.

따라서 이번 실험에서는 Random Forest가 Logistic Regression보다 더 나은 성능을 보이는 모델로 판단하였다. 그러나 Random Forest에서도 많은 False Negative가 발생하여 암 환자를 충분히 탐지하지 못하는 한계가 존재하였다.

또한 본 데이터는 정상 클래스가 약 88%, 암 클래스가 약 12%로 클래스 불균형이 존재하기 때문에 Accuracy만으로 모델의 성능을 판단해서는 안 된다. 특히 갑상선암과 같이 실제 암 환자를 놓치는 것이 중요한 문제에서는 Recall과 F1-score를 함께 고려해야 한다.

이번 분석을 통해 분류 문제에서는 단순히 높은 Accuracy를 얻는 것보다 문제의 특성과 클래스 불균형을 고려하여 적절한 평가 지표를 선택하고, 여러 모델의 성능을 비교하는 것이 중요하다는 점을 확인하였다.

6. 참고 자료

1. An Introduction to Statistical Learning
<https://www.statlearning.com/>
2. R: The R Project for Statistical Computing
<https://www.r-project.org/>
3. randomForest: Breiman and Cutler's Random Forests for Classification and Regression
<https://cran.r-project.org/package=randomForest>
4. R Documentation: Generalized Linear Models
<https://stat.ethz.ch/R-manual/R-devel/library/stats/html/glm.html>