

DACON 갑상선암 진단 분류 데이터

모델 설계 및 학습, 평가 보고서

2026-2 COW AI팀 사전 과제 · 3주차

1~2주차 요약

- 결측치·이상치: 없음 (IQR, Z-score 모두 0건)
- 타겟(Cancer) 불균형: 양성(0) 88.0% / 악성(1) 12.0%
- 전처리: 이진 범주형 Binary Encoding, 다범주형(Country, Race) One-Hot Encoding, 수치형 5종 StandardScaler
- Feature Engineering: 가족력·방사선노출·요오드결핍 합산 Risk_Score(0~3) 파생 변수 생성, 값이 커질수록 악성 비율 증가

3-1. 머신러닝 이론

머신러닝이란 무엇인가

머신러닝(Machine Learning)은 정답이 정해진 규칙을 사람이 직접 프로그래밍하는 대신, 데이터를 통해 패턴을 스스로 학습하여 새로운 입력에 대한 예측을 수행하는 알고리즘 및 모델을 다루는 분야이다. 데이터와 정답(레이블)이 함께 주어지면 모델이 입력과 출력 사이의 관계를 학습하고(지도학습), 정답 없이 데이터의 구조나 군집을 찾기도 한다 (비지도학습).

카네기멜론 대학교의 Tom M. Mitchell 교수는 저서 <Machine Learning>(1997)에서 머신러닝을 더 엄밀하게 정의하였다. 그는 어떤 컴퓨터 프로그램이 특정 작업 범주(Task, T)에 대해 성능 측정 지표(Performance measure, P)로 평가했을 때, 경험(Experience, E)이 쌓일수록 그 성능이 향상된다면 그 프로그램은 'E로부터 학습한다'고 말할 수 있다고 정의하였다. 이 정의는 머신러닝 문제를 T(무엇을 할 것인가), P(성능을 어떻게 측정할 것인가), E(무엇으로부터 배울 것인가) 세 요소로 명확히 분해하여 설계할 수 있게 해준다는 점에서 지금도 널리 인용되는 개념이다.

본 과제를 이 틀에 대입하면 다음과 같이 정리할 수 있다.

요소	본 과제에서의 정의
Task (T)	환자의 검진 정보로부터 갑상선암 양성/악성 여부를 분류하는 것
Performance (P)	Accuracy, Precision, Recall, F1-score, ROC-AUC 등 분류 성능 지표
Experience (E)	Cancer 레이블이 포함된 학습 데이터(train.csv) 87,159건

분류(Classification)와 회귀(Regression)의 차이

- 분류(Classification):** 출력값이 '양성/악성'과 같이 이산적인 범주(클래스)인 문제이다. 본 과제의 Cancer(0/1) 예측이 대표적인 이진 분류 문제이다.
- 회귀(Regression):** 출력값이 연속적인 수치인 문제이다. 예를 들어 집값이나 온도를 예측하는 문제가 회귀에 해당한다. 즉 분류는 '어떤 범주에 속하는가'를, 회귀는 '얼마인가'를 예측한다는 점에서 다르다.

대표적인 머신러닝 모델 3가지와 특징

모델	특징
로지스틱 회귀 (Logistic Regression)	선형 결합에 시그모이드 함수를 적용하여 클래스에 속할 확률을 추정하는 분류 모델. 구조가 단순하고 해석이 쉬우며 학습 속도가 빠르지만, 변수 간 비선형 관계를 포착하기 어려움
결정 트리 (Decision Tree)	변수 기준으로 데이터를 반복적으로 분할하여 트리 형태의 규칙을 만드는 모델. 해석이 직관적이고 스케일링이 필요 없지만, 트리가 깊어지면 과적합 되기 쉬움
랜덤 포레스트 (Random Forest)	여러 개의 결정 트리를 배깅(Bagging) 방식으로 앙상블하여 예측을 종합(다수결/평균)하는 모델. 단일 트리보다 과적합에 강하고 변수 중요도를 함께 제공하지만, 개별 트리보다 해석이 어렵고 학습 비용이 큼

3-2. 데이터 분할

Train / Validation 분할

DACON에서 제공한 test.csv는 Cancer(정답) 레이블이 없는 실제 제출용 평가 데이터이므로 모델 성능을 직접 확인할 수 없다. 따라서 레이블이 있는 train.csv(87,159건)를 다시 **학습용(Train, 80%, 69,727건)**과 **검증용(Validation, 20%, 17,432건)**으로 분할하여, 검증용 데이터로 모델 성능을 사전에 가늠하였다.

데이터를 분리하여 학습하는 이유

모델을 학습에 사용한 데이터로 그대로 평가하면 모델이 그 데이터를 '암기'했을 뿐인지, 실제로 일반화된 패턴을 학습했는지 구분할 수 없다. 학습에 전혀 사용하지 않은 데이터로 평가해야 새로운(미래의) 데이터에 대한 예측 성능을 신뢰성 있게 추정할 수 있으며, 이를 통해 과적합(Overfitting) 여부도 점검할 수 있다. 또한 타겟 클래스가 88:12로 불균형하므로, 분할 시 `stratify` 옵션을 사용해 학습/검증 데이터의 클래스 비율을 원본과 동일하게 유지하였다. 아울러 수치형 변수의 Scaling(StandardScaler)은 **학습 데이터로만 fit**하고 검증 데이터에는 transform만 적용하여, 검증 데이터의 정보가 학습 과정에 유출(Data Leakage)되지 않도록 하였다.

3-3. 모델 학습

모델 선택 이유

서로 다른 성격의 모델 두 가지를 학습하여 비교하였다.

- **로지스틱 회귀:** 해석이 쉬운 선형 모델로, 성능의 기준선(baseline)을 확인하기 위해 사용하였다.
- **랜덤 포레스트:** 변수 간 비선형적 상호작용(예: Risk_Score와 다른 변수의 조합 효과)을 포착할 수 있고, 범주형·수치형이 섞인 표 형태 데이터에서 일반적으로 우수한 성능을 보이며, 변수 중요도를 함께 확인할 수 있어 선택하였다.

두 모델 모두 타겟 불균형(88:12)을 고려하여 `class_weight='balanced'` 옵션을 적용하였다. 이는 소수 클래스(악성)의 오분류에 더 큰 가중치를 부여하여, 모델이 다수 클래스(양성)만 예측하는 방향으로 치우치는 것을 완화하기 위함이다.

사용한 하이퍼파라미터

모델	하이퍼파라미터
Logistic Regression	<code>max_iter=1000</code> , <code>class_weight='balanced'</code> , 나머지 기본값
Random Forest	<code>n_estimators=300</code> (트리 개수), <code>max_depth=10</code> (과적합 방지를 위한 깊이 제한), <code>class_weight='balanced'</code> , <code>random_state=42</code>

학습 과정

학습용 데이터(X_train, y_train)로 두 모델을 각각 `fit()` 하고, 검증용 데이터(X_val, y_val)에 대한 예측 확률과 예측 클래스를 구하여 3-4에서 비교하였다.

3-4. 모델 평가

평가 지표 설명

- **Accuracy(정확도):** 전체 예측 중 맞춘 비율. 클래스 불균형이 심한 경우(본 데이터 88:12) 다수 클래스만 예측해도 높게 나올 수 있어 단독으로는 신뢰하기 어렵다.
- **Precision(정밀도):** 모델이 '악성'이라고 예측한 것 중 실제로 악성인 비율로, 양성을 악성으로 잘못 예측하는 위양성(False Positive)을 얼마나 피했는지 나타낸다.
- **Recall(재현율):** 실제 악성 중 모델이 악성으로 맞게 예측한 비율로, 실제 악성 환자를 놓치지 않는지(위음성 최소화)를 나타낸다. 암 진단 문제에서는 실제 악성을 정상으로 오진(위음성)하면 치료 시기를 놓칠 수 있어 특히 중요하다.
- **F1-score:** Precision과 Recall의 조화평균으로, 두 지표의 균형을 하나의 값으로 요약한다.
- **ROC-AUC:** 임계값(threshold)을 변화시켜가며 True Positive Rate와 False Positive Rate의 관계를 그린 ROC 곡선 아래 면적으로, 임계값에 무관한 전반적인 분류 성능을 나타낸다(1에 가까울수록 우수).

평가 결과

모델	Accuracy	Precision	Recall	F1-score	ROC-AUC
Logistic Regression	0.6538	0.1967	0.6114	0.2977	0.6686
Random Forest	0.8799	0.4995	0.4412	0.4685	0.6850




그림 1. Confusion Matrix 비교 (좌: Logistic Regression, 우: Random Forest)




그림 2. ROC Curve 비교

Accuracy, Precision, F1, ROC-AUC는 Random Forest가 Logistic Regression보다 전반적으로 우수했다. 다만 **Recall만큼은 오히려 Logistic Regression이 더 높았다**(LR 0.611 vs RF 0.441). Confusion Matrix를 보면 Logistic Regression은 실제 악성 2,092명 중 1,279명을 악성으로 예측했지만 정상을 악성으로 잘못 예측한 위양성이 5,222건에 달했다. 반면 Random Forest는 위양성을 925건으로 크게 줄였지만, 실제 악성 환자 중 1,169명(약 56%)을 양성으로 오분류하였다. 즉 두 모델은 **위양성-위음성 트레이드오프**가 뚜렷하게 갈렸다.

변수 중요도 (Random Forest)




그림 3. Random Forest 변수 중요도 상위 15개

2주차에 직접 설계한 파생 변수 **Risk_Score가 중요도 1위**를 기록하였으며, 그 뒤를 Race_ASN, Family_Background, Country_IND, Iodine_Deficiency, Radiation_History 등 1주차 EDA에서 악성 비율과 연관이 높았던 변수들이 뒤따랐다. 호르몬 수치(T4_Result, TSH_Result, T3_Result)와 Nodule_Size도 중위권의 중요도를 보였다. 이를 통해 EDA 단계에서 발견한 패턴과 직접 설계한 Feature Engineering이 실제 모델 성능에 기여함을 확인할 수 있었다.

오분류 분석 (Random Forest 기준)

구분	건수	비율
검증 데이터 전체	17,432	100%
위음성 (실제 악성 → 양성으로 오분류)	1,169	6.71%
위양성 (실제 양성 → 악성으로 오분류)	925	5.31%

위음성 사례를 Risk_Score 기준으로 살펴보면, Risk_Score 0~1(위험 요인이 0~1개)인 사례가 위음성 전체의 약 90.6%(1,059/1,169건)를 차지하였다. 전체 검증 데이터에서 Risk_Score 0~1이 차지하는 비중(87.8%)보다 다소 높아, 가족력·방사선 노출력·요오드 결핍과 같은 뚜렷한 위험 신호가 없는데도 실제로는 악성인 경우, 모델이 호르몬 수치(TSH/T4/T3)나 Nodule_Size 같은 상대적으로 약한 신호만으로는 악성 여부를 판별하기 어렵하다는 것을 시사한다. 반대로 위험 요인이 많은데도 실제로는 양성인 경우 역시 존재하여, 현재 변수만으로는 완전히 분리되지 않는 영역이 있음을 보여준다.

어떤 지표를 가장 중요하게 보았는지

암 진단 문제의 특성상 실제 악성을 놓치는 위음성의 비용이 위양성보다 훨씬 크다고 판단하여, Accuracy보다 **Recall과 ROC-AUC**를 가장 중요한 지표로 고려하였다. 이 기준으로 보면 전체적인 지표(Accuracy, Precision, F1)는 Random Forest가 우수하지만, 실제 악성 환자를 더 많이 찾아내는 능력(Recall)은 Logistic Regression이 더 뛰어나다는 점에서 단일 지표만으로 '더 나은 모델'을 단정하기 어렵다. 실제 서비스에 적용한다면 Random Forest에 **임계값(threshold) 조정**을 적용해 Recall을 끌어올리는 방향을 우선 검토할 필요가 있다.

결론

- Accuracy, Precision, F1, ROC-AUC는 Random Forest가 Logistic Regression보다 우수했다. 다만 Recall은 오히려 Logistic Regression이 더 높아(LR 0.611 vs RF 0.441), 암 진단처럼 Recall이 중요한 문제에서는 이 트레이드오프를 신중히 고려해야 함을 확인하였다.
- 변수 중요도 상위권에 2주차에 직접 설계한 파생 변수 Risk_Score가 1위로 나타나, 직접 수행한 Feature Engineering이 실제로 모델 성능에 기여함을 확인하였다.
- 위음성 오분류 사례 분석을 통해, 향후 개선 방향으로 호르몬 수치 간 상호작용 변수 추가, 임계값(threshold) 조정을 통한 Recall 향상, 오버샘플링(SMOTE) 등 불균형 완화 기법 적용 등을 고려할 수 있다.

참고 문헌 (References)

- DAICON, "갑상선암 진단 분류 AI 알고리즘 개발 대회" 대회 상세 페이지, <https://dacon.io/competitions/official/236488/overview/description>
- Tom M. Mitchell, *Machine Learning*, McGraw-Hill, 1997. <https://www.cs.cmu.edu/~tom/files/MachineLearningTomMitchell.pdf>
- scikit-learn 공식 문서 - Logistic Regression, https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
- scikit-learn 공식 문서 - Random Forest Classifier, <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
- scikit-learn 공식 문서 - Model evaluation: quantifying the quality of predictions, https://scikit-learn.org/stable/modules/model_evaluation.html